

Projet de Fin d'Études

**Système Intelligent de Classification Explicable des
Stades du Sommeil**

(XAI-Sleep)

Présenté par :

Votre Nom

Spécialité : Génie Informatique

Encadrant industriel : M. Abdelwaheb Dahmeni, Mme Hajer Dahmeni

Encadrant académique : M. X

Lieu : Centre National de l'Informatique (CNI)

Période : 2024-2025

Remerciements

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué à la réalisation de ce projet de fin d'études.

Je remercie tout particulièrement **M. Abdelwaheb Dahmeni** et **Mme Hajer Dahmeni**, mes encadrants au Centre National de l'Informatique (CNI), pour leur disponibilité, leurs conseils avisés et leur suivi rigoureux tout au long de ce stage.

Je remercie également mon encadrant académique, **M. X**, pour ses précieuses orientations et son soutien pédagogique.

Mes remerciements s'adressent aussi à l'ensemble du personnel du CNI pour leur accueil chaleureux et leur aide précieuse, en particulier au sein du département où j'ai effectué mon stage.

Enfin, je remercie ma famille et mes amis pour leur encouragement constant durant ces mois de travail intense.

Table des matières

Table des figures

Liste des tableaux

Chapitre 1

Introduction générale

Les troubles du sommeil, tels que l'apnée du sommeil, l'insomnie ou la narcolepsie, touchent une part croissante de la population mondiale. Leur diagnostic repose sur l'examen polysomnographique (PSG), un enregistrement nocturne de multiples signaux physiologiques (EEG, EOG, EMG, ECG, etc.). L'analyse manuelle des PSG par des experts est une tâche longue, fastidieuse et sujette à une variabilité inter-évaluateur significative (accord de 70 à 85%). Face à ce constat, l'automatisation de la classification des stades du sommeil à l'aide de techniques d'apprentissage profond est devenue un axe de recherche majeur.

Cependant, les modèles de deep learning existants fonctionnent souvent comme des « boîtes noires » : ils fournissent une prédiction sans justifier leur décision. Ce manque de transparence limite leur adoption en milieu clinique, où l'explicabilité est essentielle pour la confiance et la validation médicale.

Le présent projet de fin d'études, intitulé **XAI-Sleep** (Explainable AI for Sleep Staging), vise à développer un système intelligent de classification des stades du sommeil qui soit à la fois performant et explicable. Le système repose sur un modèle d'ensemble de type *stacking* combinant CNN, LSTM et Transformer, enrichi d'un lissage contextuel localisé (LCS) pour assurer la cohérence temporelle. Des techniques d'explicabilité (SHAP, cartes de saillie, mécanismes d'attention) sont intégrées pour chaque modèle de base et pour l'ensemble, permettant aux cliniciens de comprendre les facteurs ayant conduit à chaque prédiction.

Le projet a été réalisé au sein du **Centre National de l'Informatique (CNI)** à Tunis, sous la tutelle de M. Abdelwaheb Dahmeni et Mme Hajer Dahmeni. Il s'inscrit dans la durée de six mois, de novembre 2024 à avril 2025.

Ce rapport présente l'ensemble des travaux menés. Après une présentation de l'organisme d'accueil (chapitre 1), nous détaillons le contexte médical et la problématique (chapitre 2). Un état de l'art des méthodes existantes est dressé au chapitre 3. Le chapitre 4 décrit la conception et l'architecture du système proposé, tandis que le chapitre 5 expose l'implémentation et les résultats de validation. Enfin, une conclusion générale dresse le bilan et ouvre des perspectives.

Chapitre 2

Présentation de l'organisme d'accueil : CNI

2.1 Le Centre National de l'Informatique (CNI)

Le Centre National de l'Informatique (CNI) est un établissement public à caractère non administratif, doté de la personnalité civile et de l'autonomie financière. Il a été créé le 30 décembre 1975 par la loi n° 75-83 (articles 35 à 42). Placé sous la tutelle du Ministre des Technologies de la Communication, le CNI opère dans les domaines de l'informatique et des technologies de la communication. Il est certifié ISO 9001 version 2015.

2.1.1 Missions

Le CNI constitue le principal appui aux structures publiques de l'administration pour la réalisation, le déploiement et l'exploitation des systèmes d'information. Ses missions couvrent :

- **Maîtrise d'ouvrage déléguée** : pilotage de projets.
- **Études & Conseil** : audit, études d'opportunité, schémas directeurs, cahiers des charges, conseils en réseaux et sécurité.
- **Développement** : conception, développement et maintenance de systèmes d'information, formation sur les SI développés.
- **Hébergement** : hébergement de serveurs, d'applications et de données.
- **Backup et continuité d'activité** : mise en place de solutions de reprise après sinistre, élaboration de plans de continuité.
- **Formation & certification** : formations continues, certifiantes, séminaires.
- **Déploiement et assistance utilisateurs** : déploiement des applications, assistance sur site ou à distance.

2.1.2 Historique

Le CNI a joué un rôle pionnier dans l’informatisation de l’administration tunisienne. Le diagramme ci-dessous résume les grandes étapes de son évolution.




FIGURE 2.1 – Chronologie historique du CNI

2.1.3 Intégration du projet au sein du CNI

Le projet XAI-Sleep s’inscrit dans la mission de recherche et développement du CNI, plus particulièrement dans l’axe « Études & Conseil » et « Développement ». Il répond à une volonté de modernisation des outils d’aide au diagnostic dans le secteur médical, en appliquant les technologies de l’IA explicable aux données de santé. Le CNI m’a offert un environnement favorable, avec un accès à des ressources de calcul et un encadrement de qualité.

2.2 Organisation du stage

Mon stage s’est déroulé sur une période de six mois, du 1er novembre 2024 au 30 avril 2025. Le planning prévisionnel est présenté en annexe. Les principales tâches ont été :

- Étude de la littérature sur la classification des stades du sommeil et l’IA explicable.
- Prétraitement des données PSG (Sleep-EDF).
- Conception et implémentation du modèle d’ensemble (CNN, LSTM, Transformer) avec stacking et LCS.
- Intégration des méthodes d’explicabilité (SHAP, attention, saliency).
- Développement d’une API FastAPI et d’une interface web interactive.
- Mise en place d’une pipeline CI/CD (GitHub Actions, Docker).
- Évaluation des performances et rédaction du rapport.

Chapitre 3

Contexte médical et problématique

3.1 Le sommeil et ses stades

Le sommeil humain est un état physiologique cyclique composé de plusieurs stades, définis selon les critères de l'American Academy of Sleep Medicine (AASM) :

- **Stade W (éveil)** : activité alpha/bêta, tonus musculaire élevé.
- **Stade N1 (sommeil léger)** : ralentissement du rythme cérébral, disparition des fuseaux.
- **Stade N2 (sommeil lent léger)** : présence de fuseaux et complexes K.
- **Stade N3 (sommeil lent profond)** : ondes lentes de haute amplitude.
- **Stade REM (paradoxal)** : mouvements oculaires rapides, atonie musculaire.

La classification manuelle des stades sur des enregistrements polysomnographiques (PSG) de 8 heures représente environ 6 à 8 heures de travail par patient, avec un accord inter-expert variant de 70 à 85%.

3.2 Problématique de l'automatisation

L'apprentissage profond a permis d'atteindre des performances élevées (précision > 90%) sur des bases publiques comme Sleep-EDF. Cependant, les modèles souffrent d'un manque d'explicabilité : ils ne fournissent pas de justification de leurs décisions, ce qui freine leur adoption clinique. Les médecins ont besoin de comprendre *pourquoi* un modèle a classé un épisode en N1 plutôt qu'en REM.

3.3 Objectifs du projet

Le projet vise à répondre à cette double exigence :

1. **Performance** : atteindre une précision d'au moins 90% sur le jeu de données Sleep-EDF.

2. **Explicabilité** : fournir des explications locales et globales via SHAP, les cartes de saillie et les mécanismes d'attention.

Le système devra être déployé sous forme d'une application web interactive, permettant aux cliniciens de télécharger un fichier EDF, d'obtenir un hypnogramme et des explications visuelles.

Chapitre 4

État de l’art

4.1 Classification automatique des stades du sommeil

Les premières approches utilisaient des caractéristiques extraites manuellement (spectre de puissance, entropie, etc.) et des classifieurs classiques (SVM, forêts aléatoires). Depuis 2016, les réseaux de neurones profonds dominent le domaine.

4.1.1 Modèles séquentiels : LSTM, CNN, Transformers

- Les **CNN** sont efficaces pour extraire des motifs temporels locaux (fuseaux, ondes lentes).
- Les **LSTM** (ou BiLSTM) modélisent les dépendances à long terme entre épisodes successifs.
- Les **Transformers** utilisent des mécanismes d’auto-attention pour capturer des relations globales.

Plusieurs travaux combinent CNN et LSTM (DeepSleepNet, TinySleepNet) pour atteindre une précision $> 85\%$. Les Transformers récents (e.g., SleepTransformer) obtiennent des performances supérieures à 90% sur Sleep-EDF.

4.1.2 Modèles d’ensemble

Le *stacking* consiste à combiner plusieurs modèles de base via un méta-apprenant. Il permet de réduire la variance et le biais. Des études ont montré que l’empilement de CNN, LSTM et Transformer améliore la robustesse.

4.2 Explicabilité en IA (XAI)

4.2.1 SHAP (SHapley Additive exPlanations)

Basé sur la théorie des jeux, SHAP attribue à chaque caractéristique une contribution à la prédiction. Il est applicable à tout modèle.

4.2.2 Mécanismes d'attention

Les poids d'attention dans les LSTM ou Transformers indiquent quels instants temporels sont les plus importants.

4.2.3 Cartes de saillie

Pour les CNN, les cartes de saillie (saliency maps) mettent en évidence les zones du signal les plus influentes.

4.2.4 Application au sommeil

Peu de travaux intègrent l'explicabilité dans la classification des stades du sommeil. Le projet XAI-Sleep se positionne comme une contribution originale en combinant stacking et explications multi-méthodes.

Chapitre 5

Conception et architecture du système

5.1 Gestion du projet (Méthodologie Agile)

Dans le cadre de ce projet, nous avons adopté une méthodologie Agile de type Scrum afin de permettre une évolution itérative et progressive du système.

5.1.1 Product Backlog

Le Product Backlog regroupe l'ensemble des fonctionnalités à développer, exprimées sous forme de User Stories.

ID	User Story	Priorité
US1	En tant qu'utilisateur, je peux uploader un fichier EDF afin d'analyser un enregistrement PSG	Haute
US2	En tant que système, je peux segmenter le signal en époques de 30 secondes	Haute
US3	En tant que système, je peux classifier les stades du sommeil (Wake, NREM, REM)	Haute
US4	En tant qu'utilisateur, je peux visualiser l'hypnogramme généré	Haute
US5	En tant qu'utilisateur, je peux comparer les prédictions avec un hypnogramme réel	Haute
US6	En tant qu'utilisateur, je peux visualiser les signaux EEG, EOG et EMG	Moyenne
US7	En tant que système, je peux générer des explications (SHAP, attention, saliency)	Haute
US8	En tant qu'utilisateur, je peux exporter les résultats (PDF, CSV)	Moyenne
US9	En tant que système, je peux stocker les résultats dans une base de données	Moyenne
US10	En tant qu'utilisateur, je peux naviguer entre les époques et consulter les détails	Haute

TABLE 5.1 – Product Backlog du projet

5.1.2 Planification des Sprints

Le projet a été divisé en plusieurs sprints de durée de deux semaines chacun, permettant une progression incrémentale.

5.1.2.1 Sprint 1 : Préparation des données

- Chargement des fichiers EDF
- Prétraitement des signaux
- Segmentation en époques

5.1.2.2 Sprint 2 : Modélisation

- Implémentation du modèle LSTM
- Entraînement sur les données SHHS
- Évaluation des performances

5.1.2.3 Sprint 3 : Amélioration et Explicabilité

- Intégration des techniques SHAP
- Ajout du mécanisme d'attention
- Analyse des résultats

5.1.2.4 Sprint 4 : Interface utilisateur

- Développement de l'interface web
- Visualisation des signaux
- Affichage de l'hypnogramme

5.1.2.5 Sprint 5 : Intégration et Tests

- Intégration du backend et frontend
- Tests fonctionnels
- Validation globale du système

5.1.3 Avantages de l'approche Agile

L'adoption de la méthodologie Agile a permis :

- Une meilleure gestion des priorités
- Une adaptation continue aux besoins
- Une livraison progressive des fonctionnalités
- Une amélioration continue du système

5.2 Vue d'ensemble

Le système XAI-Sleep suit une architecture client-serveur modulaire (Figure ??).




FIGURE 5.1 – Architecture globale du système

Les principaux composants sont :

- **Backend** : API FastAPI, modèle d'ensemble, moteur d'explications.
- **Frontend** : application web React (ou Streamlit) pour l'interaction.
- **Base de données** : PostgreSQL pour stocker les résultats.
- **CI/CD** : GitHub Actions, Docker, Kubernetes.

5.3 Modèle d'ensemble (stacking)

5.3.1 Modèles de base

- **CNN** : 3 blocs convolutifs (filtres 32,64,128) suivis de global average pooling.
- **LSTM** : 2 couches LSTM bidirectionnelles de 128 unités chacune.
- **Transformer** : encodeur avec 4 têtes d'attention et dimension 128.

Chaque modèle prend en entrée des épisodes de 30 secondes (3000 échantillons) des deux canaux EEG (Fpz-Cz, Pz-Oz) ou 5 EEG (Fpz-Cz, Pz-Oz ou sec), EOG (R,L) et EMG canaux . Les sorties (logits ou probabilités) sont concaténées.

5.3.2 Méta-apprenant avec LCS

Le méta-apprenant est un réseau de neurones à 2 couches cachées. Un **lissage contextuel localisé** (LCS) est appliqué après la prédiction : il utilise une fenêtre glissante (taille 5) pour lisser les transitions aberrantes (par ex. $W \rightarrow \text{REM} \rightarrow W$), en s'appuyant sur les probabilités et les règles cliniques (interdiction des transitions impossibles).

5.4 Moteur d'explicabilité

Pour chaque modèle de base et pour l'ensemble, plusieurs méthodes sont disponibles :

- **SHAP** : calcul des valeurs SHAP sur l'ensemble des caractéristiques (moyenne par canal).
- **Attention** : extraction des poids d'attention du LSTM et du Transformer.
- **Saliency** : gradient de la sortie par rapport à l'entrée pour le CNN.

Ces explications sont fusionnées dans un tableau de bord interactif.

5.5 Interface utilisateur

L'interface web (Figure ??) permet :

- Téléchargement d'un fichier EDF.
- Visualisation des signaux bruts.
- Affichage de l'hypnogramme prédit.
- Navigation épisode par épisode avec explications (SHAP, attention).
- Export PDF/JSON.



FIGURE 5.2 – Maquette de l'interface utilisateur

5.6 Automatisation du déploiement

Une pipeline CI/CD avec GitHub Actions construit une image Docker de l'application, l'exécute sur un cluster Kubernetes (minikube en développement, cloud en production). Les tests unitaires et d'intégration sont automatisés.

Chapitre 6

Implémentation et validation

6.1 Environnement technique

- Langages : Python 3.10, TypeScript/React.
- Frameworks : PyTorch, FastAPI, Streamlit (prototypage).
- Librairies : MNE, Scikit-learn, SHAP, Captum.
- Conteneurisation : Docker, Kubernetes.

6.2 Prétraitement des données

Nous avons utilisé la base **Sleep-EDF** (version 2018) étendue, comprenant 196 sujets. Les étapes :

1. Chargement des fichiers EDF avec MNE.
2. Sélection des canaux :
 - **2 canaux** : EEG Fpz-Cz et EEG Pz-Oz.
 - **5 canaux** : les deux EEG + EOG horizontal + EMG submental + ECG (ou un canal supplémentaire selon la configuration).
3. Filtrage passe-bande (0,5–35 Hz) et rééchantillonnage à 100 Hz.
4. Segmentation en épisodes de 30 secondes (3000 points).
5. Normalisation par épisode (z-score).
6. Division entraînement / validation / test : 70% / 15% / 15% (au niveau des sujets).

6.3 Modèles entraînés

Nous avons évalué trois architectures (LSTM, CNN, Transformer) sur deux configurations de canaux (2 et 5) et deux nombres de classes (3 : Éveil, NREM, REM; et 5 : W, N1, N2, N3, REM). Soit un total de 12 modèles. Chaque modèle a été entraîné pendant 30 époques avec early stopping sur le kappa de Cohen.

Les hyperparamètres sont détaillés dans le tableau ??.

TABLE 6.1 – Hyperparamètres des modèles

Paramètre	Valeur
Batch size	64
Optimiseur	Adam
Learning rate (LSTM/CNN)	1e-3
Learning rate (Transformer)	1e-4
Fonction de perte	CrossEntropyLoss
Dropout	0,3 (LSTM/CNN), 0,1 (Transformer)
Nombre de couches LSTM	2 (bidirectionnel)
Filtres CNN	32, 64, 128
Têtes d'attention (Transformer)	4

6.4 Résultats expérimentaux

6.4.1 Performances globales

Le tableau ?? résume les meilleures précisions et kappa obtenus sur le jeu de test.

TABLE 6.2 – Résultats globaux des 12 modèles

Modèle	Canaux	Classes	Accuracy (%)	Kappa
LSTM	5	3	90,86	0,8430
CNN	5	3	91,66	0,8527
Transformer	5	3	90,14	0,8260
LSTM	2	5	76,01	0,6793
CNN	2	5	79,90	0,7232
Transformer	2	5	77,15	0,6864
LSTM	2	3	87,58	0,7901
CNN	2	3	89,10	0,8095
Transformer	2	3	86,92	0,7714
LSTM	5	5	78,60	0,7131
CNN	5	5	82,78	0,7605
Transformer	5	5	81,55	0,7422

Le meilleur modèle est le **CNN avec 5 canaux et 3 classes** (Éveil, NREM, REM) : précision de 91,66% et kappa de 0,8527.

6.4.2 Analyse détaillée du meilleur modèle

Les matrices de confusion et rapports de classification sont présentés ci-dessous.




FIGURE 6.1 – Courbe d'apprentissage du CNN 5 canaux 3 classes



FIGURE 6.2 – Matrice de confusion normalisée (CNN 5ch, 3 classes)

TABLE 6.3 – Rapport de classification détaillé (CNN 5ch, 3 classes)

Classe	Précision	Rappel	F1-score	Support
Wake	0,94	0,92	0,93	5990
NREM	0,92	0,94	0,93	11001
REM	0,84	0,79	0,82	2522
Moyenne macro	0,90	0,88	0,89	19513
Moyenne pondérée	0,92	0,92	0,92	19513

On observe une très bonne discrimination entre Éveil et NREM, et une performance satisfaisante pour la classe REM ($F1 = 0,82$). Les erreurs principales se situent entre REM et NREM (confusion de 21% des REM classés en NREM).

6.4.3 Comparaison des architectures

Le tableau ?? montre que le CNN surpasse légèrement le LSTM et le Transformer pour la tâche à 3 classes. Pour la tâche à 5 classes, les performances chutent (82% max), ce qui justifie le choix de la granularité à 3 classes pour l’application clinique ciblée (détection des apnées).

TABLE 6.4 – Comparaison des architectures (5 canaux, 3 classes)

Modèle	Accuracy (%)	Kappa
LSTM	90,86	0,8430
CNN	91,66	0,8527
Transformer	90,14	0,8260

6.5 Explicabilité : exemples avec SHAP

Nous avons appliqué SHAP sur le meilleur modèle CNN pour expliquer les prédictions individuelles. La figure ?? montre les valeurs SHAP pour un épisode correctement classé REM.



FIGURE 6.3 – Attributions SHAP pour un épisode REM

Les échantillons autour de 250–500 ms (correspondant aux mouvements oculaires rapides) contribuent positivement à la classe REM, tandis que les zones de fort ralentissement (ondes lentes) contribuent négativement.

6.6 Validation croisée et robustesse

Une validation croisée à 5 plis sur les 196 sujets a confirmé la stabilité des performances : écart-type de l'accuracy inférieur à 0,8% pour le modèle CNN 5 canaux 3 classes.

6.7 Déploiement et performances temporelles

L'inférence d'une nuit complète (environ 1000 épisodes) prend 8 minutes sur un GPU NVIDIA T4, soit 0,48 seconde par épisode. L'API FastAPI répond en moins de 2 secondes par requête. Le système conteneurisé (Docker) a été déployé sur un cluster Kubernetes de test.

6.8 Synthèse des résultats

- Le modèle **CNN à 5 canaux (EEG+EOG+EMG+ECG) en 3 classes (Éveil, NREM, REM)** atteint 91,66% de précision, dépassant l'objectif des 90% fixé dans le cahier des charges.
- La version 5 classes reste utile pour la recherche, mais moins performante (82,78% max).
- Les explications SHAP sont cohérentes avec la physiologie du sommeil.
- Le système est prêt pour une intégration clinique après validation complémentaire sur d'autres bases (MESA, SHHS).