

2025 – 2026

PROJET DE FIN D'ÉTUDES

DIPLÔME NATIONAL D'INGÉNIEUR

SPÉCIALITÉ : ArcTic

HYPNORIA

*Système intelligent de classification des stades du sommeil avec IA explicable,
appliqué à la prédiction expliquée de la sévérité du syndrome d'apnées
obstructives du sommeil*

Réalisé par : Aymen Ftita

Encadrant ESPRIT : M^{me} Ines Chouchane

Encadrants entreprise : M. Abdelouaheb Dahmeni et M^{me} Hajer Dahmeni





Je valide le dépôt du rapport de projet de fin d'études relatif à l'étudiant nommé ci-dessous :

- **Nom & Prénom :** Aymen Ftita

Encadrants entreprise

- **Nom & Prénom :** M. Abdelouaheb Dahmeni
- **Nom & Prénom :** M^{me} Hajer Dahmeni

Cachet & Signature

Encadrante académique

- **Nom & Prénom :** M^{me} Ines Chouchane

Signature

Ce formulaire doit être rempli, signé et scanné.

Ce formulaire doit être introduit après la page de garde.





Dédicaces

À mes parents, dont le soutien n'a jamais faibli et dont les encouragements m'ont porté jusqu'ici.

À ma famille, pour sa présence constante et pour la confiance qu'elle m'a accordée tout au long de ce parcours.

À mes amis, qui ont su être présents dans les moments d'effort comme dans ceux de doute.

À mes enseignants d'ESPRIT, pour la formation qu'ils m'ont transmise et pour l'exigence qu'ils m'ont appris à m'imposer.

Cette réalisation est le fruit de l'engagement et du soutien de chacun d'entre vous. Je vous en suis profondément reconnaissant.

Aymen Ftita





Remerciements

Je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont rendu ce projet de fin d'études possible.

Je remercie tout particulièrement **M. Abdelouaheb Dahmeni** et **M^{me} Hajer Dahmeni**, mes encadrants au Centre National de l'Informatique, pour leur disponibilité constante, la pertinence de leurs conseils et la rigueur de leur suivi tout au long de ces six mois. Leur confiance m'a laissé la liberté d'explorer, et leurs remarques m'ont évité bien des impasses.

J'adresse mes remerciements à **M^{me} Ines Chouchane**, mon encadrante académique à ESPRIT, pour ses orientations méthodologiques et son accompagnement pédagogique, qui ont structuré ce travail autant que son rendu écrit.

Je remercie l'ensemble du personnel du Centre National de l'Informatique pour son accueil et son aide, en particulier au sein du département où s'est déroulé mon stage.

Mes remerciements vont également aux membres du jury, qui me font l'honneur d'évaluer ce travail, ainsi qu'à l'ensemble du corps enseignant d'ESPRIT pour la formation reçue durant ces années.

Je remercie enfin ma famille et mes amis, qui m'ont supporté pendant ces six mois.





Table des matières

Dédicaces	3
Remerciements	4
Liste des acronymes	13
Introduction générale	15
1 Présentation générale	16
1.1 Cadre général du stage	16
1.2 Présentation de l'organisme d'accueil	16
1.2.1 Le Centre National de l'Informatique	16
1.2.2 Services proposés par le CNI	17
1.2.3 Intégration du projet au sein du CNI	17
1.3 Présentation du projet	17
1.3.1 Le sommeil et sa structure	17
1.3.2 La polysomnographie	19
1.3.3 Le syndrome d'apnées obstructives du sommeil	20
1.3.4 Objectif général du projet	20
1.3.5 Problématique	20
1.3.5.1 Le coût du scorage manuel	20
1.3.5.2 La variabilité inter-scoreur	21
1.3.5.3 L'opacité des modèles d'apprentissage profond	21
1.4 Étude préalable	21
1.4.1 Étude de l'existant	21
1.4.1.1 Les solutions commerciales	21
1.4.1.2 Les travaux académiques	22
1.4.2 Critique de l'existant	23
1.4.3 Solution proposée	24
1.5 Méthodologie de travail	24
1.5.1 Choix du cadre Scrum	24
1.5.2 Les rôles dans la méthodologie Scrum	24
1.5.3 Adaptation au projet	24
1.5.4 Organisation en releases	24
2 Analyse et spécification des besoins	26
2.1 Identification des acteurs	26
2.2 Étude des besoins	27
2.2.1 Les besoins fonctionnels	27
2.2.2 Les besoins non fonctionnels	27
2.3 Diagramme de cas d'utilisation global	28
2.4 Backlog du produit	32





2.5	Diagramme de classes	35
2.6	Environnement de travail	36
2.6.1	Frameworks et langages utilisés	36
2.6.2	Environnement logiciel	37
2.6.3	Environnement matériel	38
2.7	Architecture globale	38
2.7.1	Architecture logique	38
2.7.2	Architecture fonctionnelle du pipeline d'analyse	39
2.7.3	Architecture physique	40
2.8	Planification des releases	41
2.8.1	Découpage en releases	41
2.8.2	Découpage en sprints	42
2.8.3	Vélocité	43
2.8.4	Planning	44
3	Release 1 : Moteur de classification des stades	46
3.1	Présentation de la release	46
3.1.1	Objectif de la release	46
3.1.2	Backlog de la release	46
3.2	Sprint 1 : Préparation des données et amorçage	47
3.2.1	Objectif du sprint	47
3.2.2	Sprint Backlog	47
3.2.3	Analyse	48
3.2.3.1	Diagramme des cas d'utilisation	48
3.2.3.2	Description textuelle des cas d'utilisation	50
3.2.4	Conception	50
3.2.4.1	Diagramme de séquence objet	50
3.2.5	Réalisation	51
3.2.5.1	La chaîne de préparation	51
3.2.5.2	Le corpus produit	52
3.2.5.3	Découpage et pondération	53
3.2.6	Revue du sprint	53
3.3	Sprint 2 : Modèles de classification des stades	53
3.3.1	Objectif du sprint	53
3.3.2	Sprint Backlog	53
3.3.3	Analyse	54
3.3.3.1	Diagramme des cas d'utilisation	54
3.3.3.2	Description textuelle des cas d'utilisation	55
3.3.4	Conception	56
3.3.4.1	Diagramme de séquence objet	56
3.3.4.2	Réseau convolutif multi-échelle	56
3.3.4.3	Réseau récurrent à pooling attentionnel	57
3.3.4.4	Réseau attentionnel par patches	57
3.3.5	Réalisation	58
3.3.5.1	Stratégie d'entraînement sous contrainte matérielle	58
3.3.5.2	Résultats	60
3.3.6	Revue du sprint	62
3.4	Revue de la release 1	62





3.4.1	Incrément livré	62
3.4.2	Rétrospective	63
4	Release 2 : Diagnostic expliqué et poste de travail	64
4.1	Présentation de la release	64
4.1.1	Objectif de la release	64
4.1.2	Backlog de la release	64
4.2	Sprint 3 : Ensembles et prédiction de la sévérité	65
4.2.1	Objectif du sprint	65
4.2.2	Sprint Backlog	65
4.2.3	Analyse	67
4.2.3.1	Diagramme des cas d'utilisation	67
4.2.3.2	Description textuelle des cas d'utilisation	68
4.2.4	Conception	69
4.2.4.1	Diagramme de séquence objet	69
4.2.5	Réalisation	69
4.2.5.1	Combinaison des modèles par empilement	69
4.2.5.2	Prédiction de la sévérité du syndrome d'apnées	71
4.2.5.3	Explicabilité des prédictions	75
4.2.5.4	Synthèse méthodologique	77
4.2.6	Revue du sprint	78
4.3	Sprint 4 : Service d'inférence et poste de travail	78
4.3.1	Objectif du sprint	78
4.3.2	Sprint Backlog	78
4.3.3	Analyse	80
4.3.3.1	Diagramme des cas d'utilisation	80
4.3.3.2	Description textuelle des cas d'utilisation	81
4.3.4	Conception	81
4.3.4.1	Diagrammes de séquence objet	81
4.3.5	Réalisation	83
4.3.5.1	Organisation de l'interface applicative	83
4.3.5.2	Points d'entrée	84
4.3.5.3	Sécurité des accès	85
4.3.5.4	Poste de travail du praticien	85
4.3.6	Revue du sprint	88
4.4	Revue de la release 2	88
4.4.1	Incrément livré	88
4.4.2	Rétrospective	88
5	Release 3 : Plateforme clinique et industrialisation	90
5.1	Présentation de la release	90
5.1.1	Objectif de la release	90
5.1.2	Backlog de la release	90
5.2	Sprint 5 : Dossier patient et gouvernance	90
5.2.1	Objectif du sprint	91
5.2.2	Sprint Backlog	91
5.2.3	Analyse	92
5.2.3.1	Diagramme des cas d'utilisation	92
5.2.3.2	Description textuelle des cas d'utilisation	93





5.2.4	Conception	93
5.2.4.1	Diagramme d'états	93
5.2.5	Réalisation	94
5.2.5.1	Persistance et cloisonnement	94
5.2.5.2	Archivage sur stockage objet	94
5.2.5.3	Administration et cycle de vie des licences	94
5.2.5.4	Traçabilité	95
5.2.5.5	Limites au regard du règlement européen	95
5.2.6	Revue du sprint	95
5.3	Sprint 6 : Collaboration, restitution et industrialisation	96
5.3.1	Objectif du sprint	96
5.3.2	Sprint Backlog	96
5.3.3	Analyse	98
5.3.3.1	Diagramme des cas d'utilisation	98
5.3.3.2	Description textuelle des cas d'utilisation	98
5.3.4	Conception	99
5.3.4.1	Diagramme de séquence objet	99
5.3.5	Réalisation	99
5.3.5.1	Consultations confraternelles	99
5.3.5.2	Annotation et comparaison aux normes	100
5.3.5.3	Production du compte rendu	100
5.3.5.4	Multilinguisme et thème sombre	100
5.3.5.5	Conteneurisation	101
5.3.5.6	Intégration continue	101
5.3.6	Revue du sprint	102
5.4	Revue de la release 3	102
5.4.1	Incrément livré	102
5.4.2	Validation fonctionnelle	103
5.4.3	Rétrospective	104
Conclusion générale et perspectives		106
	Bilan du travail	106
	Apports du projet	107
	Limites	107
	Perspectives	107
	Mot de la fin	108
Bibliographie		109





Table des figures

1	Chronologie du Centre National de l'Informatique	16
2	Hypnogramme d'une nuit physiologique	18
3	Époque polysomnographique de 30 secondes	19
4	Cycle Scrum adapté au projet	25
5	Diagramme de cas d'utilisation global	29
6	Raffinement du cas « Analyser un enregistrement »	30
7	Diagramme de classes du modèle métier	35
8	Schéma relationnel de la base	36
9	Architecture générale du système	38
10	Architecture fonctionnelle du pipeline d'analyse	40
11	Vue de déploiement	41
12	Feuille de route des releases	42
13	Vélocité par sprint	44
14	Diagramme de Gantt du projet	44
15	Diagramme des cas d'utilisation du sprint 1 — préparation des données	49
16	Diagramme de séquence objet du sprint 1 — préparation d'un enregistrement	51
17	Chaîne de traitement du signal	51
18	Distribution des stades dans le corpus SHHS1	52
19	Diagramme des cas d'utilisation du sprint 2 — classification des stades	55
20	Diagramme de séquence objet du sprint 2 — entraînement d'un modèle	56
21	Architecture du réseau convolutif	57
22	Architecture du réseau récurrent	57
23	Architecture du modèle attentionnel	58
24	Courbes d'apprentissage du modèle convolutif	60
25	Matrices de confusion des trois architectures	61
26	Matrice de confusion à cinq classes	62
27	Diagramme des cas d'utilisation du sprint 3 — diagnostic et explication	67
28	Séquence de prédiction de la sévérité	69
29	Principe de l'empilement de modèles	70
30	Comparaison des κ pour l'ensemble à cinq classes	71
31	Matrice de confusion de l'ensemble	71
32	Pipeline de prédiction de la sévérité	72
33	Distribution des marqueurs selon la sévérité	73
34	Comparaison des six classifieurs en validation croisée	73
35	Matrice de confusion de la prédiction de sévérité	74
36	Courbes ROC de la prédiction de sévérité	75
37	Taxonomie des méthodes d'explication	75
38	Lecture en cascade d'une explication SHAP	76
39	Importance globale des variables	77





40	Diagramme des cas d'utilisation du sprint 4 — poste de travail du médecin	80
41	Séquence d'authentification	82
42	Séquence d'analyse d'un enregistrement	83
43	Documentation OpenAPI générée automatiquement	85
44	Assistant d'analyse, étape 1 : déclaration du montage	86
45	Assistant d'analyse, étape 2 : granularité de classification	87
46	Écran de progression du traitement	87
47	Restitution des résultats d'analyse	87
48	Prédiction de sévérité à partir d'une saisie manuelle	88
49	Diagramme des cas d'utilisation du sprint 5 — dossier patient et gouvernance	92
50	Cycle de vie d'un examen	93
51	Registre des médecins et gestion des licences	94
52	Gestion des établissements rattachés	95
53	Journal d'audit : consultation et export	95
54	Diagramme des cas d'utilisation du sprint 6 — collaboration et restitution	98
55	Diagramme de séquence objet du sprint 6 — sollicitation d'un confrère	99
56	Fil de discussion rattaché à un examen	100
57	Compte rendu clinique généré	100
58	Tableau de bord du médecin en thème sombre	101
59	Exécution de la chaîne d'intégration continue	102





Liste des tableaux

1	Les cinq états de vigilance définis par le référentiel AASM	18
2	Dérivations minimales d'un montage polysomnographique de scorage	19
3	Classes de sévérité du SAOS selon l'index d'apnées-hypopnées	20
4	Principales suites commerciales d'analyse polysomnographique	22
5	Principaux travaux de classification automatique des stades du sommeil	23
6	Positionnement de HYPNORIA face aux suites commerciales	23
7	Acteurs du système et leurs responsabilités	26
8	Regroupement des besoins fonctionnels en épics	27
9	Besoins non fonctionnels et moyens de vérification	28
10	Description textuelle du cas « Analyser un enregistrement »	31
11	Description textuelle du cas « Prédire la sévérité du SAOS »	32
12	Product Backlog — 60 récits utilisateur, 358 points	33
13	Technologies retenues et motifs de choix	37
14	Environnement logiciel	37
15	Décisions d'architecture et leur justification	39
16	Planification du projet en trois releases	41
17	Découpage des releases en sprints	43
18	Backlog de la release 1	46
19	Sprint Backlog — Sprint 1	48
20	Description textuelle du cas « Préparer un enregistrement »	50
21	Sprint Backlog — Sprint 2	54
22	Description textuelle du cas « Classer une époque »	55
23	Empreinte du corpus d'entraînement en simple précision	58
24	Stratégies de résidence des données pendant l'entraînement	59
25	Performances des douze modèles de base sur le jeu de test	60
26	Performances par classe — configuration à cinq dérivations	61
27	Revue de la release 1 : incrément attendu et incrément livré	63
28	Backlog de la release 2	64
29	Sprint Backlog — Sprint 3	66
30	Description textuelle du cas « Prédire la sévérité du SAOS »	68
31	Ensembles par empilement, comparés aux modèles de base et au vote moyen	70
32	Approches d'évaluation du risque de SAOS	72
33	Prédiction de la sévérité — résultats sur les 530 sujets de test	74
34	Sprint Backlog — Sprint 4	79
35	Description textuelle du cas « Analyser un enregistrement »	81
36	Modules de l'interface applicative	84
37	Mécanismes de sécurité et menaces couvertes	85
38	Principaux composants de l'interface	86
39	Revue de la release 2 : incrément attendu et incrément livré	88





40	Backlog de la release 3	90
41	Sprint Backlog — Sprint 5	91
42	Description textuelle du cas « Gérer le cycle de vie d'un compte »	93
43	Sprint Backlog — Sprint 6	97
44	Description textuelle du cas « Solliciter un confrère »	98
45	Services de la pile conteneurisée	101
46	Travaux de la chaîne d'intégration continue	102
47	Revue de la release 3 : incrément attendu et incrément livré	103
48	Scénarios de validation fonctionnelle	104





Liste des acronymes

AASM	<i>American Academy of Sleep Medicine</i> — société savante dont le manuel constitue le référentiel international de scorage du sommeil
API	<i>Application Programming Interface</i> — interface de programmation applicative
AUC	<i>Area Under the Curve</i> — aire sous la courbe ROC
CNI	Centre National de l'Informatique
CNN	<i>Convolutional Neural Network</i> — réseau de neurones convolutif
CPAP	<i>Continuous Positive Airway Pressure</i> — pression positive continue
CSV	<i>Comma-Separated Values</i> — format tabulaire à valeurs séparées
ECG	Électrocardiogramme
EDF	<i>European Data Format</i> — format standard d'échange des signaux physiologiques
EEG	Électroencéphalogramme
EMG	Électromyogramme
EOG	Électro-oculogramme
IAH	Index d'Apnées-Hypopnées — nombre moyen d'événements respiratoires par heure de sommeil
JWT	<i>JSON Web Token</i> — jeton d'authentification signé
LSTM	<i>Long Short-Term Memory</i> — réseau récurrent à mémoire longue
MESA	<i>Multi-Ethnic Study of Atherosclerosis</i> — cohorte épidémiologique diffusée par le NSRR
MLOps	<i>Machine Learning Operations</i> — industrialisation du cycle de vie des modèles
NREM	<i>Non-Rapid Eye Movement</i> — sommeil sans mouvements oculaires rapides
NSRR	<i>National Sleep Research Resource</i> — plateforme de diffusion des cohortes de recherche sur le sommeil
ORM	<i>Object-Relational Mapping</i> — correspondance objet-relationnel
PSG	Polysomnographie — enregistrement nocturne multi-signaux de référence
RAM	<i>Random Access Memory</i> — mémoire vive
RBAC	<i>Role-Based Access Control</i> — contrôle d'accès fondé sur les rôles
RDI	<i>Respiratory Disturbance Index</i> — index de perturbation respiratoire
REM	<i>Rapid Eye Movement</i> — sommeil paradoxal
REST	<i>Representational State Transfer</i> — style d'architecture pour les services web
RGPD	Règlement Général sur la Protection des Données
ROC	<i>Receiver Operating Characteristic</i> — courbe de performance d'un classifieur binaire
SAOS	Syndrome d'Apnées Obstructives du Sommeil
SE	<i>Sleep Efficiency</i> — efficacité du sommeil, rapport du temps de sommeil au temps passé au lit





SHAP	<i>SHapley Additive exPlanations</i> — méthode d'explication fondée sur les valeurs de Shapley
SHHS	<i>Sleep Heart Health Study</i> — cohorte multicentrique américaine d'étude du sommeil et du risque cardiovasculaire
SOL	<i>Sleep Onset Latency</i> — latence d'endormissement
SPT	<i>Sleep Period Time</i> — durée de la période de sommeil
TIB	<i>Time In Bed</i> — temps passé au lit
TST	<i>Total Sleep Time</i> — temps de sommeil total
VRAM	<i>Video Random Access Memory</i> — mémoire du processeur graphique
WASO	<i>Wake After Sleep Onset</i> — durée d'éveil intra-sommeil
XAI	<i>eXplainable Artificial Intelligence</i> — intelligence artificielle explicable
XML	<i>eXtensible Markup Language</i> — langage de balisage extensible





Introduction générale

Les troubles du sommeil constituent un problème de santé publique dont l'ampleur reste largement sous-estimée. Le syndrome d'apnées obstructives du sommeil, à lui seul, concernerait près d'un milliard d'adultes dans le monde, dont une large majorité n'a jamais été diagnostiquée. Son examen de référence, la polysomnographie, enregistre une nuit complète de signaux physiologiques ; son interprétation impose ensuite à un technicien qualifié de classer manuellement un millier de fenêtres de trente secondes, puis de caractériser les événements respiratoires. Ce goulet d'étranglement humain, davantage que la capacité d'enregistrement, limite aujourd'hui l'accès au diagnostic.

L'apprentissage profond a apporté une réponse crédible au premier problème. Depuis 2017, plusieurs architectures atteignent sur les bases publiques un niveau de concordance comparable à celui observé entre deux experts humains. Leur adoption clinique demeure pourtant marginale, faute de transparence. Un réseau de neurones profond restitue une classe sans énoncer ce qui l'a déterminée, alors que le praticien engage sa responsabilité sur le compte rendu qu'il signe. Sans justification intelligible, une prédiction ne peut être ni validée ni contestée.

Le présent projet de fin d'études, mené au sein du Centre National de l'Informatique, répond à cette double exigence de performance et de transparence. Il aboutit à HYPNORIA, une plateforme web d'aide à l'interprétation polysomnographique organisée autour de deux étages d'apprentissage. Le premier classe automatiquement les stades du sommeil à partir d'un enregistrement brut, en combinant par empilement trois familles d'architectures : convolutive, récurrente et attentionnelle. Le second exploite l'hypnogramme ainsi produit pour prédire la classe de sévérité du syndrome d'apnées, et accompagne chaque prédiction de la décomposition des facteurs qui l'ont déterminée. Autour de ces modèles, la plateforme fournit la chaîne applicative complète attendue en contexte clinique : dossier patient, archivage sécurisé, annotation, compte rendu exportable, collaboration entre praticiens et traçabilité des actions.

Ce mémoire rend compte de l'ensemble de ces travaux, organisés selon les releases successives du produit. Le chapitre 1 pose le cadre du projet : l'organisme d'accueil, les notions médicales indispensables, la problématique, l'étude de l'existant et la méthodologie Scrum retenue. Le chapitre 2 formalise les besoins, présente le *Product Backlog* et l'architecture globale, puis planifie le projet en trois releases de deux sprints chacune. Les trois chapitres suivants sont consacrés chacun à une release, détaillée sprint par sprint. Le chapitre 3 livre le moteur de classification des stades, de la préparation du corpus à l'entraînement des modèles. Le chapitre 4 en fait un diagnostic expliqué accessible au praticien, par la combinaison des modèles, la prédiction de la sévérité et la construction du poste de travail. Le chapitre 5 complète la plateforme clinique : dossier patient, gouvernance, collaboration, restitution et industrialisation. Une conclusion générale dresse enfin le bilan des objectifs atteints et ouvre sur les perspectives.





1 Présentation générale

Introduction

Ce premier chapitre situe le projet dans son double contexte : celui de l'organisme qui l'a accueilli et celui de la médecine du sommeil. Nous présentons le cadre du stage, l'organisme d'accueil et son activité, puis les notions médicales indispensables à la compréhension du mémoire. De ce contexte émerge une problématique que nous confrontons aux solutions existantes, avant d'en déduire le périmètre de la solution proposée et la méthodologie retenue pour la construire.

1.1 Cadre général du stage

Ce projet de fin d'études s'est déroulé du 26 janvier au 26 juillet 2026, soit six mois, au sein du Centre National de l'Informatique à Tunis. Il a été encadré côté entreprise par M. Abdelouaheb Dahmeni et M^{me} Hajer Dahmeni, et côté académique par M^{me} Ines Chouchane.

Le projet consiste à concevoir et réaliser HYPNORIA, une plateforme web d'aide à l'interprétation des enregistrements polysomnographiques. Il couvre l'ensemble du cycle de développement : constitution du corpus de données, entraînement et évaluation de modèles d'apprentissage, conception et développement de l'application, puis conteneurisation et automatisation du déploiement.

1.2 Présentation de l'organisme d'accueil

1.2.1 Le Centre National de l'Informatique

Le Centre National de l'Informatique (CNI) est un établissement public à caractère non administratif, doté de la personnalité civile et de l'autonomie financière. Il a été créé par la loi n° 75-83 du 30 décembre 1975, dont les articles 35 à 42 fixent son statut et ses attributions. Placé sous la tutelle du ministère chargé des technologies de la communication, il est certifié ISO 9001 version 2015.

Le CNI constitue le principal appui technique des structures publiques tunisiennes pour la conception, le déploiement et l'exploitation de leurs systèmes d'information. Il intervient aussi bien en maîtrise d'ouvrage déléguée qu'en réalisation directe, et opère une infrastructure d'hébergement mutualisée au service de l'administration.

Le CNI a accompagné toutes les vagues d'informatisation de l'administration tunisienne, depuis les traitements centralisés des années 1970 jusqu'aux services numériques contemporains. La figure 1 en retrace les principaux jalons.




FIGURE 1 Principaux jalons de l'évolution du Centre National de l'Informatique.





1.2.2 Services proposés par le CNI

Les missions du CNI couvrent l'ensemble du cycle de vie d'un système d'information public :

- **Maîtrise d'ouvrage déléguée** : pilotage de projets pour le compte des administrations bénéficiaires.
- **Études et conseil** : audits, études d'opportunité, schémas directeurs, rédaction de cahiers des charges, conseil en réseaux et en sécurité des systèmes d'information.
- **Développement** : conception, réalisation et maintenance applicative, accompagnée de la formation des utilisateurs aux systèmes livrés.
- **Hébergement** : exploitation de serveurs, d'applications et de données pour le compte des organismes publics.
- **Continuité d'activité** : solutions de sauvegarde, plans de reprise après sinistre et plans de continuité.
- **Formation et certification** : formations continues et certifiantes, séminaires techniques.
- **Déploiement et assistance** : mise en production des applications, support sur site ou à distance.

1.2.3 Intégration du projet au sein du CNI

Le projet HYPNORIA s'inscrit dans les axes « Études et conseil » et « Développement » du CNI. Il relève d'une démarche exploratoire : appliquer les techniques d'apprentissage automatique récentes à l'aide au diagnostic médical, domaine où l'administration tunisienne dispose de gisements de données mais de peu d'outils d'exploitation.

Trois caractéristiques du contexte CNI ont orienté les choix techniques du projet :

- **La souveraineté des données.** Les données de santé sont sensibles. L'architecture retenue sépare strictement les métadonnées cliniques, stockées dans une base relationnelle maîtrisée, des fichiers volumineux, confiés à un stockage objet dont l'accès n'est possible que par des liens signés à durée limitée.
- **La reproductibilité du déploiement.** Le CNI exploite des systèmes sur une longue durée. L'ensemble de la plateforme est donc conteneurisé et démarrable en une seule commande.
- **La traçabilité.** Toute action sensible est journalisée avec son auteur, son horodatage et son adresse d'origine, et le journal est exportable en vue d'un contrôle de conformité.

1.3 Présentation du projet

1.3.1 Le sommeil et sa structure

Le sommeil n'est pas un état homogène de repos mais une succession organisée d'états physiologiques distincts, qui se répètent au cours de la nuit selon des cycles d'une durée moyenne de 90 minutes. On distingue le sommeil sans mouvements oculaires rapides, ou *NREM*, subdivisé en stades de profondeur croissante, et le sommeil paradoxal, ou *REM*, caractérisé par une activité cérébrale proche de l'éveil associée à une atonie musculaire complète.

La classification de référence est celle de l'*American Academy of Sleep Medicine* [1], qui a succédé en 2007 aux règles de Rechtschaffen et Kales [2]. Elle définit cinq états, décrits au tableau 1, et impose que le scoring se fasse par fenêtres, ou *époques*, de 30 secondes.





Stade	Signature électrophysiologique	Éléments caractéristiques	Part typique
W (éveil)	Rythme alpha postérieur, activité bêta, tonus musculaire élevé	Mouvements oculaires volontaires et clignements	—
N1	Ralentissement du rythme de fond, ondes thêta	Mouvements oculaires lents, transition instable	5 %
N2	Activité thêta dominante	Fuseaux du sommeil et complexes K	45 % à 55 %
N3	Ondes lentes de grande amplitude, sur plus de 20 % de l'époque	Sommeil profond, seuil d'éveil élevé	15 % à 25 %
REM	Rythme rapide et désynchronisé, proche de l'éveil	Mouvements oculaires rapides, atonie musculaire	20 % à 25 %

TABLE 1 Les cinq états de vigilance définis par le référentiel AASM

Deux points conditionnent la difficulté de la tâche d'automatisation. D'une part, la distribution des stades est fortement déséquilibrée : le N2 représente à lui seul environ la moitié d'une nuit, tandis que le N1 en occupe à peine un vingtième. D'autre part, le stade N1 est un état de transition sans marqueur graphique propre : il se définit par la disparition du rythme alpha et l'absence des fuseaux du N2, c'est-à-dire négativement. C'est la classe sur laquelle les experts humains eux-mêmes s'accordent le moins.

La succession des stades attribués aux époques successives constitue l'hypnogramme (figure 2), document de référence du médecin du sommeil : il condense environ mille décisions élémentaires en une seule courbe.




FIGURE 2 Hypnogramme schématique d'une nuit physiologique de huit heures. Les bandes vertes signalent les épisodes de sommeil paradoxal.





1.3.2 La polysomnographie

L'hypnogramme n'est pas une mesure directe mais une interprétation. Il découle d'un examen appelé polysomnographie, qui enregistre simultanément plusieurs signaux physiologiques pendant une nuit complète. La figure 3 en montre une époque de 30 secondes, l'unité élémentaire sur laquelle porte le scorage. Le tableau 2 décrit les dérivations minimales requises pour établir ce scorage, qui sont précisément celles exploitées dans ce travail.




FIGURE 3 *Tracé illustratif d'une époque de 30 secondes en stade N2. Le complexe K et les deux fuseaux portés par les dérivations centrales sont les grapho-éléments qui définissent ce stade ; l'électro-oculogramme ne montre aucun mouvement rapide et l'électromyogramme mentonnier garde un tonus de fond.*

Signal	Nombre	Apport au scorage
Électroencéphalogramme (EEG)	2	Rythme de fond, fuseaux, complexes K et ondes lentes : c'est le signal qui porte la décision
Électro-oculogramme (EOG)	2	Distingue les mouvements oculaires lents de l'endormissement des mouvements rapides du sommeil paradoxal
Électromyogramme (EMG) mentonnier	1	Le tonus musculaire sépare le sommeil paradoxal du sommeil lent : son effondrement signe le REM

TABLE 2 Dérivations minimales d'un montage polysomnographique de scorage

Un montage complet comporte en pratique d'autres capteurs (flux nasal, sangles thoraciques, oxymétrie de pouls, électrocardiogramme) destinés à la caractérisation des événements respiratoires. Le scorage des stades, lui, ne requiert que les cinq dérivations ci-dessus. Cette distinction a une conséquence pratique : elle rend possible un système compatible avec des montages allégés, et nous évaluerons d'ailleurs une configuration réduite à deux dérivations.





1.3.3 Le syndrome d'apnées obstructives du sommeil

Le syndrome d'apnées obstructives du sommeil (SAOS) résulte d'obstructions répétées des voies aériennes supérieures pendant le sommeil. Chaque obstruction provoque une désaturation en oxygène et un micro-éveil, invisible pour le patient mais destructeur pour l'architecture du sommeil.

Sa prévalence est élevée : une analyse publiée en 2019 estime à environ 936 millions le nombre d'adultes de 30 à 69 ans présentant un SAOS léger à sévère dans le monde, dont près de 425 millions sous une forme modérée à sévère [3]. Non traité, le syndrome est associé à une surmorbidity cardiovasculaire documentée [4], et il reste largement sous-diagnostiqué [5].

La sévérité s'exprime par l'index d'apnées-hypopnées, nombre moyen d'événements respiratoires par heure de sommeil. Le référentiel AASM [6] en définit quatre classes, reprises au tableau 3, qui constituent les classes cibles du second modèle développé dans ce mémoire.

Classe	IAH (évén./h)	Conduite habituelle
Normal	< 5	Pas de traitement spécifique
Léger	5 à < 15	Mesures hygiéno-diététiques, surveillance
Modéré	15 à < 30	Traitement discuté selon la symptomatologie
Sévère	≥ 30	Traitement par pression positive continue indiqué

TABLE 3 Classes de sévérité du SAOS selon l'index d'apnées-hypopnées

Au-delà des événements respiratoires qu'il provoque, le SAOS déforme l'architecture du sommeil. Les micro-éveils répétés fragmentent la nuit, suppriment le sommeil profond et raccourcissent les épisodes paradoxaux. Cette empreinte est mesurable sur le seul hypnogramme, indépendamment des capteurs respiratoires, hypothèse sur laquelle repose le second volet du projet.

1.3.4 Objectif général du projet

HYPNORIA est une plateforme web d'aide à l'interprétation polysomnographique destinée aux médecins du sommeil. Elle poursuit quatre objectifs :

1. **Automatiser le scorage des stades** à partir d'un fichier d'enregistrement brut au format EDF, avec une exactitude comparable à l'accord inter-expert.
2. **Prédire la sévérité du SAOS** à partir de l'architecture du sommeil et de marqueurs cliniques, sans exiger l'annotation manuelle des événements respiratoires.
3. **Expliquer chaque prédiction** en exposant les facteurs qui l'ont déterminée, afin que le praticien puisse la valider ou la contester.
4. **Fournir la chaîne applicative complète** : dossier patient, archivage sécurisé, annotation, compte rendu exportable, collaboration et administration multi-établissements.

1.3.5 Problématique

Trois constats fondent ce projet.

1.3.5.1 Le coût du scorage manuel

Une nuit d'enregistrement de huit heures produit environ un millier d'époques de 30 secondes. Chacune doit être examinée, comparée à ses voisines et classée par un technicien qualifié. L'opération représente plusieurs heures





de travail expert par patient, auxquelles s'ajoutent l'analyse des événements respiratoires et la rédaction du compte rendu. Dans un service saturé, le facteur limitant n'est plus le nombre de lits d'enregistrement mais le temps d'expertise disponible pour interpréter ce qu'ils produisent.

1.3.5.2 La variabilité inter-scoreur

Le scoring manuel est en outre imparfaitement reproductible. Le programme de fiabilité inter-scoreurs de l'AASM mesure un accord global de l'ordre de 83 % [7], avec des écarts marqués selon le stade [8].

Deux conséquences en découlent. La première est méthodologique : les annotations de référence ne sont pas une vérité absolue mais l'opinion d'un scoreur, et l'accord inter-expert constitue donc un plafond de performance réaliste. La seconde est clinique : elle légitime l'automatisation, car un modèle présente au moins la propriété d'être parfaitement reproductible.

1.3.5.3 L'opacité des modèles d'apprentissage profond

Depuis 2017, les réseaux de neurones profonds atteignent sur les bases publiques des performances comparables à celles d'un scoreur humain [9, 10]. Le verrou s'est donc déplacé de la précision vers l'adoption.

Un modèle d'apprentissage profond fonctionne comme une boîte noire : il produit une classe sans énoncer ce qui l'a déterminée. Or le praticien engage sa responsabilité sur le diagnostic qu'il signe, et ne peut ni valider ni contester une décision dont il ignore les motifs. À ce frein pratique s'ajoute un cadre réglementaire européen qui reconnaît un droit à l'explication pour les décisions automatisées [11].

Ces trois constats convergent : la médecine du sommeil a besoin d'un système qui soit à la fois rapide, pour absorber le volume d'examen, reproductible, pour lever la variabilité inter-scoreur, et transparent, pour que le praticien puisse s'en porter garant.

1.4 Étude préalable

1.4.1 Étude de l'existant

1.4.1.1 Les solutions commerciales

Le marché de l'analyse polysomnographique est dominé par des logiciels propriétaires adossés à du matériel d'acquisition : *Noxturnal* de Nox Medical, *Sleepware G3* de Philips Respironics, *ProFusion PSG* de Compumedics ou encore *SleepWorks* de Natus. Une seconde génération d'acteurs, dont *EnsoSleep* d'EnsoData, propose un scoring automatique fondé sur l'apprentissage profond.

Le tableau 4 récapitule ces cinq suites.





	Solution	Éditeur	Matériel associé	Scorage automatique
	Noxturnal	Nox Medical, Islande	enregistreurs Nox A1 et T3	assisté, règles paramétrables
	Sleepware G3	Philips Respironics, Pays-Bas	systèmes Alice	assisté
	ProFusion PSG	Compumedics, Australie	systèmes Graef et Sesta	assisté
	SleepWorks	Natus Medical, États-Unis	plateformes Embla	assisté
	EnsoSleep	EnsoData, États-Unis	indépendant du constructeur	apprentissage profond

TABLE 4 Principales suites commerciales d'analyse polysomnographique

En Tunisie, les laboratoires du sommeil s'appuient sur ces mêmes suites, acquises avec le matériel d'enregistrement. Le coût de licence et l'adhérence au matériel du constructeur en limitent la diffusion, et aucune solution nationale d'analyse automatique n'est à notre connaissance disponible.

1.4.1.2 Les travaux académiques

La littérature scientifique a produit une succession d'architectures de plus en plus performantes, résumées au tableau 5. *DeepSleepNet* [9] combine une extraction convolutive multi-échelle et une modélisation séquentielle récurrente sur un unique canal. *TinySleepNet* [12] en propose une version allégée. *U-Sleep* [10] montre une robustesse au montage et à la cohorte. *SleepTransformer* [13] introduit un mécanisme d'auto-attention ainsi qu'une forme d'interprétabilité par les poids d'attention. *XSleepNet* [14] exploite conjointement la représentation temporelle brute et la représentation temps-fréquence.





Travail	Année	Approche	Évaluation	Exactitude
Fraiwan <i>et al.</i> [15]	2012	Temps-fréquence + forêt aléatoire	jeu propriétaire	≈ 83 %
Tsinalis <i>et al.</i> [16]	2016	CNN sur EEG brut	Sleep-EDF	≈ 82 %
DeepSleepNet [9]	2017	CNN multi-échelle + BiLSTM	Sleep-EDF	≈ 82 %
Chambon <i>et al.</i> [17]	2018	CNN multivarié (EEG, EOG, EMG)	MASS	≈ 83 %
SleepEEGNet [18]	2019	CNN + séquence à séquence	Sleep-EDF	≈ 84 %
TinySleepNet [12]	2020	CNN + LSTM allégés	Sleep-EDF	≈ 85 %
AttnSleep [19]	2021	Multi-résolution + auto-attention	Sleep-EDF	≈ 84 %
U-Sleep [10]	2021	Entièrement convolutif	15 cohortes	F1 macro ≈ 0,79
SleepTransformer [13]	2022	Transformer hiérarchique	SHHS	≈ 88 %
XSleepNet [14]	2022	Fusion brut + temps-fréquence	SHHS	≈ 89 %

TABLE 5 Principaux travaux de classification automatique des stades du sommeil

1.4.2 Critique de l'existant

Les suites commerciales sont matures et validées cliniquement, mais présentent quatre limites au regard de notre problématique. L'adhérence matérielle contraint les laboratoires disposant d'un parc hétérogène. Le coût de licence, calibré pour des structures hospitalières occidentales, reste hors de portée de nombreux centres. L'installation locale est peu compatible avec le travail à distance et la collaboration entre praticiens de sites différents. Enfin, lorsqu'un scoring automatique est proposé, il l'est sans explication des facteurs qui l'ont produit.

Les travaux académiques, de leur côté, visent la performance de classification évaluée sur des jeux publics et s'arrêtent au modèle. Aucun ne livre la chaîne applicative qui permettrait à un praticien d'en faire usage : gestion des patients, archivage des examens, production d'un compte rendu, collaboration.

Le tableau 6 confronte les suites commerciales aux besoins identifiés.

Critère	Suites commerciales	HYPNORIA
Scoring automatique	partiel	oui
Indépendance au matériel	faible	oui
Explicabilité des décisions	non	oui
Prédiction de la sévérité SAOS	indirecte	oui
Application web multi-utilisateurs	non	oui
Dossier patient et historique	oui	oui
Collaboration entre praticiens	non	oui
Traçabilité et audit	partielle	oui
Coût d'acquisition	élevé	nul

TABLE 6 Positionnement de HYPNORIA face aux suites commerciales





1.4.3 Solution proposée

Il ressort de cette analyse un espace non couvert, à l'intersection des deux familles : une plateforme applicative complète, indépendante du matériel d'acquisition, qui intègre des modèles de l'état de l'art *et* les explique. C'est cet espace que le projet occupe.

Le système s'articule autour de deux étages d'apprentissage successifs et d'une plateforme qui les met à disposition. Le premier étage assure la classification des stades : trois familles d'architectures (convolutive, récurrente et attentionnelle) sont entraînées séparément puis combinées par un méta-apprenant. Deux configurations de montage et deux granularités de sortie sont proposées, afin de couvrir aussi bien l'enregistrement de laboratoire que le dispositif ambulatoire. Le second étage assure la prédiction de la sévérité : il extrait de l'hypnogramme produit une vingtaine de marqueurs d'architecture du sommeil, les complète de données cliniques et oxymétriques, et prédit la classe de sévérité en accompagnant chaque prédiction de sa décomposition en contributions par variable.

1.5 Méthodologie de travail

1.5.1 Choix du cadre Scrum

Le projet présentait deux sources d'incertitude difficilement compatibles avec une planification linéaire. La première tenait aux données : l'accès aux cohortes cliniques est soumis à une autorisation dont le délai d'instruction n'était pas connu à l'avance. La seconde tenait aux modèles : rien ne garantissait *a priori* qu'une architecture donnée atteindrait le niveau de performance visé, ni que l'empilement apporterait un gain.

Une démarche séquentielle aurait figé des décisions avant de disposer des éléments permettant de les prendre. Nous avons donc retenu le cadre Scrum [20], dont le principe est d'avancer par incréments courts et d'ajuster la suite à ce que chaque incrément a révélé.

1.5.2 Les rôles dans la méthodologie Scrum

Scrum définit trois rôles. Le *Product Owner* porte la vision du produit, arbitre les priorités du backlog et valide la valeur livrée. Le *Scrum Master* garantit le respect du cadre, anime les cérémonies et lève les obstacles. L'*équipe de développement* réalise l'incrément.

Le projet étant mené par une seule personne, ces rôles ont été redistribués sans être dénaturés : la fonction de Product Owner a été portée par l'encadrement professionnel du CNI, celle de Scrum Master par l'encadrement académique lors des points de suivi, et celle d'équipe de développement par l'étudiant.

1.5.3 Adaptation au projet

La durée d'itération a été portée à quatre semaines plutôt que deux. Ce choix est directement lié à la nature du travail : l'entraînement d'un modèle profond sur près de deux cent mille exemples se compte en heures de calcul, et douze variantes devaient être produites. Une itération de deux semaines n'aurait pas permis de livrer un incrément évaluable pendant la phase de modélisation.

Trois artefacts ont été tenus à jour : le *Product Backlog*, liste priorisée des fonctionnalités attendues ; le *Sprint Backlog*, sous-ensemble sélectionné pour l'itération en cours ; et l'*incrément*, version fonctionnelle livrée en fin de sprint. Les cérémonies ont été condensées : une réunion de planification en début de sprint, un point hebdomadaire avec l'encadrement en substitution de la mêlée quotidienne, une revue de sprint sous forme de démonstration et une rétrospective écrite.

1.5.4 Organisation en releases

Au-dessus du sprint, un second niveau de planification a été retenu : la release, version livrable du produit qui regroupe plusieurs sprints autour d'un objectif de valeur commun. Ce niveau répond à une réalité du projet : un sprint isolé, comme celui consacré à l'entraînement des modèles, ne produit pas toujours à lui seul une version





exploitable, alors que deux sprints consécutifs orientés vers un même objectif le peuvent.

Le projet a ainsi été planifié en trois releases de deux sprints chacune. Chaque release s'ouvre par la constitution de son backlog, sous-ensemble du *Product Backlog* qu'elle s'engage à livrer, et se clôt par une revue au cours de laquelle l'incrément est démontré dans son ensemble, suivie d'une rétrospective qui oriente la release suivante (figure 4). Ce découpage structure les chapitres de réalisation du présent mémoire : chacun est consacré à une release.




FIGURE 4 Cycle Scrum adapté à un projet individuel de six mois, organisé en releases de deux sprints.

Conclusion

Ce chapitre a posé le cadre du projet. Nous avons présenté le Centre National de l'Informatique et montré comment trois de ses contraintes structurantes ont orienté les choix techniques. Nous avons ensuite introduit les notions médicales nécessaires : les cinq stades du référentiel AASM, l'hypnogramme, le montage polysomnographique et les classes de sévérité du SAOS.

De ce contexte se dégage une problématique à trois volets : le coût du scoring manuel, sa variabilité entre experts et l'opacité des modèles qui prétendent l'automatiser. L'étude de l'existant a montré que les suites commerciales et les travaux académiques traitent chacun une partie du problème sans le couvrir entièrement, laissant ouvert l'espace qu'occupe HYPNORIA.

Le chapitre suivant traduit ces intentions en une spécification vérifiable : acteurs, besoins fonctionnels et non fonctionnels, backlog du produit, modèle de données, architecture globale et planification des releases.





2 Analyse et spécification des besoins

Introduction

Le chapitre précédent a établi ce qu'il fallait construire et pourquoi. Celui-ci formalise la commande. Nous identifions d'abord les acteurs du système et leurs responsabilités, puis nous exprimons les besoins fonctionnels et non fonctionnels. Ces besoins sont ensuite traduits en un *Product Backlog* de soixante récits utilisateur, priorisés et estimés. Nous présentons enfin le modèle de données, l'environnement de travail, l'architecture globale et la planification du backlog en trois releases de deux sprints chacune, qui structure les trois chapitres suivants.

2.1 Identification des acteurs

Un acteur désigne toute entité qui interagit avec le système sans en faire partie. On distingue les acteurs *principaux*, qui déclenchent les cas d'utilisation pour en retirer une valeur, des acteurs *secondaires*, sollicités par le système pour mener une opération à bien. Le tableau 7 recense les quatre acteurs de HYPNORIA.

Acteur	Type	Responsabilités
Médecin du sommeil	principal	Constituer et suivre son registre de patients, lancer l'analyse d'un enregistrement, interpréter l'hypnogramme et la prédiction de sévérité, annoter, produire le compte rendu, solliciter un confrère
Administrateur	principal	Créer et administrer les comptes médecins, gérer les échéances de licence, rattacher les praticiens à un établissement, superviser l'activité et consulter le journal d'audit
Moteur d'inférence	secondaire	Charger les modèles, prétraiter le signal, produire la séquence de stades, calculer les métriques et les attributions d'explication
Service de stockage	secondaire	Recevoir les fichiers volumineux, les conserver de façon durable et délivrer des liens d'accès temporaires

TABLE 7 Acteurs du système et leurs responsabilités

Deux remarques sur ce découpage. Le moteur d'inférence est modélisé comme un acteur distinct bien qu'il réside dans le même processus que l'interface applicative : ce choix matérialise le fait qu'il pourrait être déporté sur une machine dédiée sans modifier les cas d'utilisation. Le service de stockage, lui, est réellement externe.





2.2 Étude des besoins

2.2.1 Les besoins fonctionnels

Les besoins fonctionnels ont été organisés en neuf *épics*, regroupements thématiques de fonctionnalités partageant un même objectif métier. Cette structure, présentée au tableau 8, sert de colonne vertébrale au backlog. Les épics y sont rangés dans l'ordre où ils ont été traités : les deux étages d'apprentissage d'abord, puis la restitution au praticien, et enfin la plateforme, sa gouvernance et son déploiement.

Épic	Intitulé	Portée	Récits	Points
E1	Classification	Lecture EDF, prétraitement, modèles de base, métriques AASM	12	95
E2	Sévérité du SAOS	Empilement, extraction de marqueurs, prédiction, explications	8	65
E3	Visualisation	Hypnogramme, oxymétrie, annotation, normes de référence	5	28
E4	Authentification	Connexion, jetons, hachage, contrôle des rôles, application des licences	5	18
E5	Dossier patient	Registre des patients, examens, historique, tableau de bord	6	24
E6	Archivage et export	Stockage cloud, liens signés, compte rendu, exports	6	36
E7	Administration	Comptes médecins, cycle de vie, établissements, audit, statistiques	10	45
E8	Collaboration	Discussions rattachées à un examen, boîte de réception	3	18
E9	Industrialisation	Conteneurisation, intégration continue, déploiement, multilinguisme	5	29
Total			60	358

TABLE 8 Regroupement des besoins fonctionnels en épics

2.2.2 Les besoins non fonctionnels

Les exigences non fonctionnelles conditionnent l'acceptabilité du système autant que ses fonctions. Elles sont d'autant plus contraignantes ici que le domaine, la donnée de santé, impose des obligations propres. Le tableau 9 les énonce avec, pour chacune, le moyen de vérification retenu : un besoin non fonctionnel qu'on ne sait pas vérifier n'est qu'une intention.





Critère	Exigence	Vérification
Sécurité	Aucun accès sans jeton valide ; mots de passe jamais stockés en clair ; cloisonnement strict entre rôles	Revue des dépendances de sécurité sur chaque route ; tentative d'accès croisé entre comptes
Confidentialité	Aucun fichier patient accessible par une URL publique ou devinable	Vérification que tout lien délivré est signé et expire
Traçabilité	Toute action sensible horodatée avec son auteur, journal exportable	Inspection du journal après un scénario complet
Performance	Analyse d'une nuit complète en quelques minutes ; interface non bloquée pendant les transferts	Chronométrage sur enregistrements réels ; transfert en arrière-plan observable
Interopérabilité	Accepter les fichiers EDF quel que soit le constructeur ; importer et exporter en formats ouverts	Résolution des canaux sur des enregistrements de provenances différentes
Ergonomie	Parcours d'analyse guidé, sans formation préalable ; retour visuel sur les traitements longs	Passage d'un utilisateur non initié sur le parcours complet
Multilinguisme	Interface intégralement disponible en français et en anglais	Revue de l'absence de chaînes non traduites
Portabilité	Déploiement complet sur une machine vierge sans configuration manuelle	Démarrage de la pile sur un poste neuf en une commande
Maintenabilité	Séparation nette des responsabilités ; ajout d'un modèle sans toucher au reste	Ajout d'une variante de modèle à titre d'essai

TABLE 9 Besoins non fonctionnels et moyens de vérification

2.3 Diagramme de cas d'utilisation global

La figure 5 présente la vue d'ensemble des interactions entre les acteurs et le système.






FIGURE 5 *Vue d'ensemble des cas d'utilisation de HYPNORIA.*

Le cas « Analyser un enregistrement » constitue le cœur fonctionnel du système. La figure 6 le décompose et fait apparaître les relations d'inclusion (sous-cas systématiquement exécutés) et d'extension (comportements optionnels).






FIGURE 6 Décomposition du cas d'utilisation central en sous-cas inclus et étendus.

Les tableaux 10 et 11 décrivent textuellement les deux cas les plus critiques. Un diagramme montre en effet la structure des interactions, mais pas leur déroulement.





Identifiant	UC-03
Acteur principal	Médecin du sommeil
Acteurs secondaires	Moteur d'inférence, service de stockage
Préconditions	Le médecin est authentifié ; sa licence est valide ; il dispose d'un fichier d'enregistrement au format EDF
Postconditions	Un examen est créé dans le dossier du patient, la séquence de stades et les métriques sont enregistrées, le fichier brut est archivé
Scénario nominal	1. Le médecin sélectionne le patient concerné. 2. Il choisit le montage disponible, à deux ou cinq dérivations. 3. Il choisit la granularité de classification, à trois ou cinq stades. 4. Il dépose le fichier d'enregistrement. 5. Le système décode le fichier, résout les dérivations et prétraite le signal. 6. Le moteur d'inférence classe chaque époque et le système calcule les métriques. 7. Le système affiche l'hypnogramme, les métriques et les alertes cliniques. 8. Le système crée l'examen et lance l'archivage du fichier en arrière-plan.
Scénarios alternatifs	• 4a — Le fichier n'est pas au format attendu : le système refuse le dépôt et le signale. • 5a — Une dérivation est absente : le système applique son repli documenté et poursuit. • 5b — L'enregistrement est plus court qu'une époque : le traitement s'interrompt avec un message explicite. • 8a — L'archivage échoue : les résultats restent consultables et le transfert est signalé en erreur.

TABLE 10 Description textuelle du cas « Analyser un enregistrement »





Identifiant	UC-04
Acteur principal	Médecin du sommeil
Acteur secondaire	Moteur d'inférence
Préconditions	Une séquence de stades est disponible, issue d'une analyse ou d'une saisie manuelle
Postconditions	Une classe de sévérité, ses probabilités et la décomposition des facteurs sont associées à l'examen
Scénario nominal	1. Le système extrait les marqueurs d'architecture depuis l'hypnogramme. 2. Le médecin complète les données démographiques et oxymétriques. 3. Il déclenche l'évaluation du risque. 4. Le système construit le vecteur de variables et comble les valeurs absentes. 5. Le moteur produit la classe de sévérité et ses probabilités. 6. Le système calcule les contributions de chaque variable. 7. Le système affiche la sévérité, les facteurs aggravants et protecteurs, et l'interprétation clinique.
Scénarios alternatifs	• 2a — Le médecin importe un rapport externe : le système en extrait les valeurs et préremplit le formulaire. • 4a — Des variables cliniques manquent : le système applique la valeur médiane de la population d'apprentissage et le signale. • 5a — Les modèles ne sont pas chargés : l'opération est refusée avec un message explicite.

TABLE 11 Description textuelle du cas « Prédire la sévérité du SAOS »

2.4 Backlog du produit

Le *Product Backlog* est la liste ordonnée de tout ce que le produit doit offrir. Chaque élément prend la forme d'un récit utilisateur suivant la formulation canonique : *en tant que ... , je veux ... , afin de ...*. Cette formulation force à énoncer le bénéficiaire et la finalité, et non seulement la fonction.

Deux attributs complètent chaque récit. La priorité suit la méthode MoSCoW : *Must have* pour ce sans quoi le produit n'a pas de sens, *Should have* pour ce qui lui donne sa valeur, *Could have* pour ce qui l'améliore sans le conditionner. L'estimation s'exprime en points de complexité sur la suite de Fibonacci, échelle relative qui compare les récits entre eux plutôt que de prétendre prédire une durée.

L'ordre de la liste suit celui de la réalisation. Les récits d'apprentissage automatique viennent en tête : la classification des stades, puis la prédiction de la sévérité, parce que c'est d'eux que dépend la valeur de tout le reste et que leur résultat était le plus incertain. Le développement de la plateforme, sa gouvernance et son déploiement ferment la liste.





TABLE 12 Product Backlog — 60 récits utilisateur, 358 points

ID	Récit utilisateur	Prio.	Pts	Spr.
E1 — Classification automatique des stades				
US-01	Lire un fichier EDF et en extraire les dérivations physiologiques	M	8	S1
US-02	Résoudre les canaux malgré l'hétérogénéité des conventions de nommage	M	5	S1
US-03	Rééchantillonner, segmenter en époques de 30 s et normaliser	M	8	S1
US-04	Valider la chaîne sur un jeu public en attendant l'accès aux cohortes	M	8	S1
US-05	Prétraiter les enregistrements de la cohorte clinique à l'échelle	M	8	S2
US-06	Classer chaque époque avec un réseau convolutif multi-échelle	M	13	S2
US-07	Classer chaque époque avec un réseau récurrent à pooling attentionnel	M	13	S2
US-08	Classer chaque époque avec un Transformer par patches	M	13	S2
US-09	Choisir la configuration d'analyse selon le montage disponible	S	5	S4
US-10	Inspecter les canaux d'un fichier avant de lancer l'analyse	S	3	S4
US-11	Calculer les métriques AASM de l'enregistrement	M	8	S4
US-12	Conserver les modèles en mémoire entre deux requêtes	S	3	S4
E2 — Ensemble et prédiction de la sévérité				
US-13	Combiner les trois modèles par un méta-apprenant	M	13	S3
US-14	Extraire les marqueurs d'architecture du sommeil depuis l'hypnogramme	M	8	S3
US-15	Prédire la sévérité du SAOS en quatre classes	M	13	S3
US-16	Exposer les facteurs aggravants et protecteurs de la prédiction	M	8	S3
US-17	Saisir les données oxymétriques et les index d'éveil	M	5	S4
US-18	Lancer une prédiction sans fichier, à partir d'une saisie manuelle	S	8	S4
US-19	Importer un rapport externe pour préremplir le formulaire clinique	S	5	S4
US-20	Lire une interprétation clinique automatique des anomalies détectées	S	5	S4
E3 — Visualisation, annotation et normes				
US-21	Visualiser l'hypnogramme de façon interactive	M	8	S4
US-22	Voir la saturation et la densité d'événements sur le même axe temporel	S	5	S4
US-23	Suivre la progression de l'analyse en cours	C	5	S4
US-24	Annoter une époque précise pour consigner une observation	S	5	S6
US-25	Situer chaque métrique par rapport aux normes de référence	S	5	S6
E4 — Authentification et contrôle d'accès				
US-26	Me connecter avec mon adresse et mon mot de passe pour accéder à la plateforme	M	5	S4
US-27	Consulter mon profil pour vérifier mon rôle et mon rattachement	M	2	S4
US-28	Stocker les mots de passe hachés pour qu'aucun ne soit lisible en base	M	3	S4

suite page suivante





Tableau 12 — suite

ID	Récit utilisateur	Prio.	Pts	Spr.
US-29	Vérifier le rôle sur chaque route pour cloisonner médecins et administrateurs	M	5	S4
US-30	Refuser la connexion d'un compte suspendu ou dont la licence a expiré	M	3	S5
E5 — Dossier patient et examens				
US-31	Enregistrer un patient avec son âge, son IMC et son sexe	M	3	S5
US-32	Lister mes patients avec leur historique d'examens	M	5	S5
US-33	Consulter la fiche détaillée d'un patient et tous ses examens	M	3	S5
US-34	Créer un examen rattaché à un patient pour y associer les résultats	M	5	S5
US-35	Mettre à jour la sévérité et les résultats d'un examen	M	3	S5
US-36	Voir la répartition des risques d'apnée de ma patientèle	S	5	S6
E6 — Archivage et exports				
US-37	Archiver le fichier brut sans bloquer l'interface	M	8	S5
US-38	Archiver l'hypnogramme et le compte rendu clinique	S	5	S5
US-39	Délivrer des liens d'accès à durée limitée	M	5	S5
US-40	Exporter les marqueurs calculés pour un autre outil	S	5	S4
US-41	Composer le compte rendu en choisissant les sections à inclure	M	8	S6
US-42	Synchroniser l'hypnogramme annoté vers le dossier	S	5	S6
E7 — Administration de la plateforme				
US-43	Créer un compte médecin pour ouvrir l'accès à un nouveau praticien	M	5	S5
US-44	Lister les médecins avec leur statut et leur échéance de licence	M	3	S5
US-45	Suspendre ou réactiver un compte et fixer sa date d'expiration	M	5	S5
US-46	Réinitialiser le mot de passe d'un médecin pour débloquent un accès perdu	S	3	S5
US-47	Créer des établissements et y rattacher des médecins	S	5	S5
US-48	Journaliser chaque action sensible avec son auteur et son horodatage	M	5	S5
US-49	Consulter le journal d'audit pour enquêter sur un incident	M	5	S5
US-50	Exporter le journal d'audit pour un contrôle de conformité	S	3	S5
US-51	Consulter les statistiques globales pour suivre l'adoption	S	3	S5
US-52	Visualiser la chaîne de traitement des modèles	C	8	S6
E8 — Collaboration entre praticiens				
US-53	Ouvrir une discussion sur un examen avec un confrère	S	8	S6
US-54	Échanger des messages dans un fil rattaché à l'examen	S	5	S6
US-55	Consulter une boîte de réception centralisée	S	5	S6
E9 — Industrialisation et déploiement				
US-56	Conteneuriser les trois services pour un déploiement reproductible	M	8	S6
US-57	Orchestrer la pile en une seule commande	M	5	S6

suite page suivante





Tableau 12 — suite

ID	Récit utilisateur	Prio.	Pts	Spr.
US-58	Automatiser tests et construction d'images à chaque livraison	S	8	S6
US-59	Basculer l'interface entre français et anglais	S	5	S6
US-60	Basculer en thème sombre pour la lecture nocturne	C	3	S6

La formulation complète a été abrégée dans le tableau pour tenir sur une ligne ; le bénéficiaire se déduit de l'épic.

2.5 Diagramme de classes

Le modèle métier s'organise autour de huit entités (figure 7). L'entité centrale est l'*examen*, qui matérialise une nuit d'enregistrement : elle porte les références vers les fichiers archivés, la classe de sévérité prédite et le document de résultats. Autour d'elle gravitent le patient qui l'a subie, les annotations que le praticien y a portées et les discussions qu'elle a suscitées.



FIGURE 7 Modèle métier : l'examen est l'entité pivot du système. Chaque classe porte ses attributs et ses opérations avec leurs types.





Le passage au modèle relationnel donne les huit tables de la figure 8.

```
hospitals (id, name, b2_bucket, billing_tier, created_at)
users (id, email, hashed_password, role, first_name, last_name,
last_login, status, license_expiry, #hospital_id)
patients (id, first_name, last_name, age, imc, gender, #doctor_id)
psgs (id, #patient_id, date, severity, report_data, edf_url,
hypnogram_url, hypnogram_annotated_url, csv_url, osa_report_url)
psg_annotations (id, #psg_id, epoch_index, note, created_at)
audit_logs (id, timestamp, user_email, user_role, action, ip_address)
file_conversations (id, #psg_id, file_type, #doctor_one_id,
#doctor_two_id, created_at)
file_messages (id, #conversation_id, #sender_id, content, timestamp)
```

clé primaire soulignée, clé étrangère précédée d'un dièse

FIGURE 8 Schéma relationnel : huit tables issues du modèle métier.

La table `users` sert les deux rôles sans se dédoubler : c'est la colonne `role` qui les sépare, et le couple `status` et `license_expiry` est évalué à chaque connexion. Le rattachement d'un patient à son praticien par `doctor_id` fonde à lui seul le cloisonnement des données. Les annotations et les messages disparaissent en cascade avec l'examen ou la discussion qui les porte. Un fil de discussion, enfin, référence exactement deux praticiens, `doctor_one_id` et `doctor_two_id`, plutôt qu'une table d'association : la collaboration a été conçue de confrère à confrère.

Deux choix méritent un commentaire. Le journal d'audit est dénormalisé : il recopie l'adresse et le rôle de l'auteur au lieu de référencer son compte. C'est délibéré, car une trace de conformité doit rester lisible même après la suppression du compte concerné, et une clé étrangère l'en empêcherait. Les références de fichiers, quant à elles, ne sont jamais transmises telles quelles : elles sont converties en liens signés à durée limitée au moment de la sérialisation de la réponse.

2.6 Environnement de travail

2.6.1 Frameworks et langages utilisés

Le tableau 13 récapitule les technologies retenues et la raison de leur choix.





Couche	Technologie	Motif du choix
Interface utilisateur	React 19 et Vite	Composition par composants et rechargement instantané pendant le développement
Visualisation	Recharts	Tracés interactifs superposables sur un axe temporel commun
Multilinguisme	react-i18next	Bascule immédiate sans rechargement de l'application
Interface applicative	FastAPI	Validation déclarative des données et documentation OpenAPI générée automatiquement
Apprentissage profond	PyTorch	Écriture naturelle des architectures et accélération graphique
Apprentissage classique	scikit-learn, XGBoost, LightGBM	Implémentations de référence et interface homogène pour la comparaison
Explicabilité	SHAP	Attributions exactes en temps polynomial sur les modèles à arbres
Traitement du signal	MNE-Python, SciPy	Lecture des formats physiologiques standards et rééchantillonnage
Persistance	PostgreSQL et SQLAlchemy	Intégrité référentielle et correspondance objet-relationnel
Stockage des fichiers	Service objet compatible S3	Fichiers volumineux hors base, liens signés à durée limitée
Conteneurisation	Docker et Docker Compose	Déploiement reproductible en une commande

TABLE 13 Technologies retenues et motifs de choix

2.6.2 Environnement logiciel

Domaine	Outils
Langage	Python 3.10
Traitement du signal	MNE-Python [21], SciPy, NumPy
Apprentissage profond	PyTorch [22] avec accélération CUDA
Apprentissage classique	scikit-learn [23], XGBoost [24], LightGBM [25]
Explicabilité	SHAP [26, 27]
Expérimentation	Jupyter, matplotlib, seaborn

TABLE 14 Environnement logiciel

Le suivi de version s'appuie sur Git, la modélisation sur des diagrammes produits directement dans la chaîne de composition du mémoire, et l'expérimentation sur des carnets Jupyter conservés dans le dépôt à titre de trace reproductible.





2.6.3 Environnement matériel

Les entraînements ont été menés sur une station équipée d'un processeur graphique NVIDIA GeForce RTX 4060 pour portable, disposant de 8,6 Go de mémoire vidéo, et de 32 Go de mémoire vive. Une seconde station, équipée d'une RTX 3060, a servi à la construction des ensembles.

Ce dimensionnement a imposé un arbitrage sur la quantité de données exploitable, développé à la section 3.3.5.1.

2.7 Architecture globale

2.7.1 Architecture logique

HYPNORIA suit une architecture client-serveur à trois couches (figure 9). La couche de présentation est une application monopage exécutée dans le navigateur du praticien. La couche applicative expose une interface de programmation sans état, qui porte à la fois la logique métier et le moteur d'inférence. La couche de persistance sépare délibérément deux natures de données : les métadonnées cliniques, structurées et interrogeables, vont dans une base relationnelle ; les fichiers volumineux partent vers un stockage objet.




FIGURE 9 Architecture en trois couches. Les modules encadrés en rouge constituent le moteur d'inférence.

Le tableau 15 récapitule quatre décisions structurantes, avec l'alternative écartée et le motif du choix.





Décision	Alternative écartée	Motif
Application monopage découpée de l'interface applicative	Application web à rendu serveur	L'analyse d'un enregistrement dure plusieurs dizaines de secondes ; un client autonome peut afficher la progression, poursuivre les transferts en arrière-plan et recomposer les visualisations sans rechargement
Moteur d'inférence hébergé dans le même processus que l'interface applicative	Service d'inférence séparé	Les modèles pèsent plusieurs centaines de mégaoctets en mémoire ; les charger une seule fois et les conserver en cache évite un coût de démarrage à chaque requête. La frontière logique reste posée pour une séparation ultérieure
Séparation métadonnées / fichiers volumineux	Stockage des fichiers en base	Un enregistrement pèse plusieurs centaines de mégaoctets. Le conserver en base dégraderait les sauvegardes et les temps de réponse, sans bénéfice transactionnel
Authentification par jeton signé, sans session serveur	Session en mémoire ou en base	L'absence d'état côté serveur autorise la réplication horizontale sans mécanisme de partage de session

TABLE 15 Décisions d'architecture et leur justification

2.7.2 Architecture fonctionnelle du pipeline d'analyse

La figure 10 suit un enregistrement depuis le dépôt du fichier EDF jusqu'au tableau de bord du médecin. Le traitement se déroule en trois étapes.

La première étape est le moteur de classification des stades. Trois réseaux reçoivent le même signal et le lisent chacun à une échelle différente : le réseau convolutif extrait des motifs locaux dans les ondes brutes, le réseau récurrent tient compte de l'ordre temporel des échantillons, et le Transformer relie par auto-attention des portions éloignées de l'enregistrement. Une couche d'empilement combine leurs sorties et produit l'hypnogramme.

La deuxième étape exploite cet hypnogramme. On en calcule les indicateurs cliniques (temps de sommeil total, éveils après endormissement, latence du sommeil paradoxal), puis des modèles d'apprentissage automatique classiques (XGBoost, forêt aléatoire, SVM) estiment le risque pathologique. Le résultat alimente le compte rendu clinique.

La troisième étape rend ces décisions lisibles. SHAP indique quels facteurs ont pesé dans l'estimation du risque, et Grad-CAM montre les zones du signal EEG sur lesquelles les réseaux se sont appuyés. Les deux sorties sont affichées dans le tableau de bord final.






FIGURE 10 *Pipeline d'analyse en trois étapes : classification des stades, analyse clinique et explication des décisions.*

2.7.3 Architecture physique

La figure 11 décrit la topologie d'exécution. Chaque service est conteneurisé et l'ensemble démarre par une commande unique. Le service de stockage est le seul élément externe à l'infrastructure.






FIGURE 11 Topologie d'exécution : trois conteneurs sur un hôte, un service de stockage externe.

2.8 Planification des releases

2.8.1 Découpage en releases

Une release est une version livrable du produit : elle regroupe plusieurs sprints autour d'un objectif de valeur commun et se clôt par une revue au cours de laquelle l'incrément est démontré dans son ensemble. Le backlog du produit a été ordonnancé en trois releases de deux sprints chacune, présentées au tableau 16 et à la figure 12.

Release	Sprints	Objectif	Incrément livrable	Pts
R1 Moteur de classification	S1 et S2 du 26 jan. au 22 mars	Constituer le corpus et entraîner les modèles de classification des stades	Corpus étiqueté et douze modèles de base évalués	76
R2 Diagnostic expliqué	S3 et S4 du 23 mars au 17 mai	Livrer au praticien un diagnostic expliqué à partir d'un enregistrement brut	Ensembles, modèle de sévérité expliqué, interface applicative et poste de travail	122
R3 Plateforme clinique	S5 et S6 du 18 mai au 12 juil.	Faire de l'outil d'analyse une plateforme gouvernée, collaborative et déployable	Dossier patient, archivage, administration, collaboration, compte rendu, pile conteneurisée	160

TABLE 16 Planification du projet en trois releases

L'ordre des releases découle des dépendances entre récits et de la répartition de l'incertitude. La première traite en priorité ce qui était à la fois le plus incertain et le plus structurant : le moteur de classification, dont dépend tout le reste. La deuxième livre le plus petit incrément porteur de la valeur centrale du projet, un diagnostic expliqué accessible au praticien. La troisième ajoute ce qui rend cet outil exploitable durablement et à plusieurs : dossier patient, gouvernance, collaboration et déploiement reproductible.






FIGURE 12 Feuille de route du projet : trois releases de deux sprints, chacune close par la livraison d'un incrément.

2.8.2 Découpage en sprints

Les vingt-six semaines du stage ont été découpées en six sprints de quatre semaines, suivis de deux semaines consacrées à la rédaction et à la préparation de la soutenance. Le tableau 17 présente l'objectif et le livrable de chacun, regroupés par release.



Sprint	Période	Objectif	Livrable	Pts
Release 1 — Moteur de classification des stades				
S1	26 jan. 22 fév.	Cadrer le projet, lancer la demande d'accès aux cohortes et prouver la faisabilité de la chaîne sans attendre l'autorisation	Chaîne de prétraitement opérationnelle et premiers modèles de faisabilité	29
S2	23 fév. 22 mars	Passer du jeu d'amorçage à la cohorte clinique et couvrir les trois familles d'architectures	Douze modèles de base entraînés et évalués	47
Release 2 — Diagnostic expliqué et poste de travail				
S3	23 mars 19 avr.	Faire coopérer les architectures, puis franchir le pas du staging vers le diagnostic expliqué	Quatre ensembles et le modèle de sévérité avec ses explications	42
S4	20 avr. 17 mai	Rendre les modèles consommables et donner au praticien un parcours guidé	API documentée et parcours complet du dépôt au compte rendu	80
Release 3 — Plateforme clinique et industrialisation				
S5	18 mai 14 juin	Transformer l'outil d'analyse en plateforme gouvernée et traçable	Dossier patient persistant, archivage cloud, espace d'administration	77
S6	15 juin 12 juil.	Couvrir le travail à plusieurs, la restitution documentaire et la reproductibilité	Collaboration, compte rendu exportable, pile conteneurisée	83

TABLE 17 Découpage des releases en sprints

2.8.3 Vitesse

La vitesse mesure le nombre de points effectivement livrés par sprint. Sa progression, représentée à la figure 13, ne décrit pas un plateau régulier, ce qui correspond à la réalité du travail : les deux premiers sprints sont absorbés par la montée en compétence sur le cadre d'apprentissage profond et par des temps d'entraînement incompressibles.

Regroupée par release, la vitesse moyenne passe de 38 points par sprint pour la première à 61 pour la deuxième et 80 pour la troisième. Ce profil reflète la nature des releases : la première est dominée par la modélisation, les suivantes par le développement applicatif, moins exposé aux temps de calcul.






FIGURE 13 Points de complexité livrés par sprint, regroupés par release.

2.8.4 Planning

La figure 14 confronte la planification aux travaux réellement menés. Le jalon le plus structurant est l'obtention de l'accès aux cohortes en semaine 5. Le recouvrement volontaire entre la demande d'accès et les travaux d'amorçage sur un jeu public traduit une décision assumée : occuper le délai administratif au lieu de le subir.




FIGURE 14 Déroulement du projet sur les vingt-six semaines du stage.

Conclusion

Ce chapitre a traduit les intentions du chapitre précédent en une commande vérifiable. Quatre acteurs ont été identifiés, les besoins fonctionnels regroupés en neuf épics et déclinés en soixante récits utilisateur, et les besoins





non fonctionnels énoncés avec leur moyen de vérification. Le modèle de données, l'environnement de travail et l'architecture globale ont été présentés.

L'ordonnancement du backlog a produit trois releases de deux sprints de quatre semaines. Les trois chapitres suivants leur sont consacrés. Chacun suit la même trame : présentation de la release et de son backlog ; pour chaque sprint, backlog, analyse, conception, réalisation et revue ; enfin, revue de la release.





3 Release 1 : Moteur de classification des stades

Introduction

Ce chapitre rend compte de la première release de HYPNORIA, menée de la semaine 1 à la semaine 8 du stage. Son enjeu est de constituer le socle sur lequel repose tout le reste du système : un corpus d'apprentissage homogène et des modèles capables de classer automatiquement les stades du sommeil. Après avoir présenté l'objectif et le backlog de la release, nous détaillons ses deux sprints (la préparation des données, puis l'entraînement des modèles) avant d'en dresser la revue.

3.1 Présentation de la release

3.1.1 Objectif de la release

La première release vise à livrer un moteur de classification des stades validé. Aucune fonctionnalité n'y est encore accessible au praticien : l'incrément attendu est un ensemble de modèles entraînés et évalués, dont dépend la valeur de toutes les releases suivantes.

Placer ce moteur en tête de la planification répond à la logique de réduction de l'incertitude exposée au chapitre 1. C'est ici que se concentraient les deux incertitudes majeures du projet : le délai d'accès aux cohortes cliniques et le niveau de performance effectivement atteignable. Les lever en premier évitait de construire une plateforme autour de modèles dont rien ne garantissait encore la qualité.

3.1.2 Backlog de la release

La release regroupe les huit premiers récits du backlog, ceux de l'épic E1, pour 76 points de complexité répartis sur deux sprints de quatre semaines (tableau 18).

Sprint	Période	Objectif du sprint	Récits	Pts
Sprint 1	26 jan. – 22 fév.	Construire la chaîne de préparation du signal et la valider sur un jeu public	US-01 à 04	29
Sprint 2	23 fév. – 22 mars	Préparer la cohorte clinique et entraîner les trois familles d'architectures	US-05 à 08	47
Total de la release			8 récits	76

TABLE 18 Backlog de la release 1

L'incrément attendu en fin de release comprend un corpus d'apprentissage étiqueté conforme au référentiel AASM et douze modèles de base couvrant trois architectures, deux montages et deux granularités.





3.2 Sprint 1 : Préparation des données et amorçage

Ce premier sprint est consacré à la constitution du corpus d'apprentissage. La qualité des modèles dépend d'abord de celle des données : avant toute architecture, il fallait transformer des enregistrements bruts hétérogènes en un corpus homogène et étiqueté. Le sprint s'est heurté à une contrainte externe, le délai d'instruction de la demande d'accès aux cohortes cliniques, que nous avons choisi d'occuper plutôt que de subir.

3.2.1 Objectif du sprint

L'objectif était double. Il s'agissait d'abord de construire la chaîne de préparation du signal : lire un fichier au format EDF quel que soit son constructeur, en extraire les cinq dérivations utiles, uniformiser la fréquence d'échantillonnage, découper le signal en fenêtres conformes au référentiel AASM et neutraliser les écarts d'amplitude entre sujets.

Il s'agissait ensuite de valider cette chaîne de bout en bout sans attendre l'autorisation d'accès aux cohortes du *National Sleep Research Resource* [28], dont l'instruction prend plusieurs semaines. Le jeu public Sleep-EDF [29], diffusé par PhysioNet [30] et immédiatement téléchargeable, a servi de banc d'essai.

Ce choix constitue le principal arbitrage de gestion de projet du stage. Attendre l'autorisation aurait immobilisé quatre semaines. Travailler sur un jeu public de substitution permettait de valider la lecture des fichiers, la résolution des dérivations, la segmentation et la boucle d'entraînement avant même de disposer des données définitives. Lorsque l'autorisation est arrivée en semaine 5, la chaîne était éprouvée et il n'a plus été question que de la rejouer à plus grande échelle.

3.2.2 Sprint Backlog

Le sprint a embarqué quatre récits utilisateur pour un total de 29 points de complexité, détaillés au tableau 19.





ID	Module	Récit utilisateur	Tâches	Estim.
US-01	Lecture des enregistrements	En tant que système, je veux lire un fichier EDF et en extraire les dérivations physiologiques	Intégrer la bibliothèque de lecture des formats physiologiques Inventorier les dérivations et la fréquence native Gérer les fichiers tronqués ou illisibles	8 pts
US-02	Résolution des canaux	En tant que système, je veux résoudre les canaux malgré l'hétérogénéité des conventions de nommage	Construire la table d'alias des cinq emplacements logiques Définir la stratégie de repli sur l'EEG principal Exiger le montage complet à l'entraînement	5 pts
US-03	Normalisation du signal	En tant que système, je veux rééchantillonner, segmenter en époques de 30 s et normaliser	Rééchantillonner à 100 Hz par méthode de Fourier Découper en fenêtres de 3 000 échantillons Centrer et réduire chaque fenêtre Sérialiser en tenseurs par sujet	8 pts
US-04	Amorçage	En tant qu'ingénieur, je veux valider la chaîne sur un jeu public avant l'accès aux cohortes cliniques	Télécharger et préparer le jeu public Entraîner un modèle de faisabilité Vérifier la boucle complète de bout en bout	8 pts

TABLE 19 Sprint Backlog — Sprint 1

3.2.3 Analyse

3.2.3.1 Diagramme des cas d'utilisation

Ce sprint ne produit pas de fonctionnalité directement visible par le praticien : il construit le socle sur lequel reposeront tous les suivants. Le cas d'utilisation principal est donc porté par le moteur d'inférence, acteur secondaire du système (figure 15).






FIGURE 15 Diagramme des cas d'utilisation du sprint 1 — préparation des données





3.2.3.2 Description textuelle des cas d'utilisation

Titre	Préparer un enregistrement
Acteur	Moteur d'inférence
Description	Transformer un enregistrement polysomnographique brut en un ensemble de fenêtres normalisées, directement exploitables par un modèle de classification
Préconditions	Un fichier au format EDF est disponible et lisible
Scénario de base	1. Le système décode le fichier et inventorie ses dérivations. 2. Il apparie chaque dérivation attendue à son équivalent dans le fichier. 3. Il ramène l'ensemble des signaux à 100 Hz. 4. Il découpe le signal en fenêtres de 3 000 échantillons. 5. Il centre et réduit chaque fenêtre indépendamment. 6. Il sérialise le résultat sous forme de tenseur accompagné de ses étiquettes.
Scénario alternatif	• 2a — Une dérivation est absente : en production, repli documenté sur l'EEG principal ; à l'entraînement, le sujet est écarté du corpus. • 4a — L'enregistrement est plus court qu'une époque : le traitement s'interrompt avec un message explicite. • 6a — L'hypnogramme de référence est absent : le sujet est écarté.

TABLE 20 Description textuelle du cas « Préparer un enregistrement »

3.2.4 Conception

3.2.4.1 Diagramme de séquence objet

La figure 16 détaille l'enchaînement des traitements appliqués à un enregistrement.






FIGURE 16 Diagramme de séquence objet du sprint 1 — préparation d'un enregistrement

3.2.5 Réalisation

3.2.5.1 La chaîne de préparation

La chaîne réalisée comporte six étapes, chacune répondant à une source de variabilité identifiée (figure 17).




FIGURE 17 Chaîne de préparation : chaque étape neutralise une source de variabilité.

Quatre décisions de traitement sont détaillées ci-dessous.

Sélection stricte des dérivations. À l'entraînement, les cinq dérivations sont exigées sous leur dénomination exacte et tout écart écarte le sujet. En production, au contraire, une table d'alias couvre les conventions de nommage des différents constructeurs et replie sur l'EEG principal une dérivation absente. Cette asymétrie est voulue : sélectivité pour la pureté du corpus d'apprentissage, tolérance pour l'interopérabilité clinique. C'est un des rares endroits du système où une même fonction est délibérément implémentée deux fois différemment.

Fusion des anciens stades 3 et 4. Les annotations des cohortes suivent encore la nomenclature de Rechtschaffen et Kales [2]. Le stade 4 est fusionné dans le N3, conformément à la révision AASM de 2007.

Comblement des époques non scorées. Les fenêtres sans stade attribué reçoivent le dernier stade valide observé ; celles qui précèdent le premier stade scoré sont considérées comme de l'éveil. Cette dernière convention est une hypothèse (l'enregistrement débute avant l'extinction des lumières) et non une donnée.

Normalisation locale par z-score. Chaque fenêtre est centrée sur sa propre moyenne et réduite par son propre écart-type, dérivation par dérivation :

$$x'_{c,n}[k] = \frac{x_{c,n}[k] - \mu_{c,n}}{\sigma_{c,n} + \varepsilon}, \quad \mu_{c,n} = \frac{1}{K} \sum_{k=1}^K x_{c,n}[k], \quad K = 3000,$$





où $\sigma_{c,n}$ est l'écart-type de la dérivation c sur la fenêtre n et $\varepsilon = 1 \times 10^{-8}$ empêche la division par zéro lorsqu'une électrode s'est détachée et que le segment est plat. Chaque fenêtre sort ainsi de moyenne nulle et de variance unitaire, ce qui met les cinq dérivation sur une même échelle et évite que l'EMG, physiquement plus faible, ne pèse rien devant l'EEG.

La statistique est donc calculée sur chaque fenêtre isolément, et non sur le corpus. Ce choix neutralise les écarts d'amplitude liés à l'impédance des électrodes, au gain de l'amplificateur et à la morphologie du sujet, ainsi que la dérive lente au cours de la nuit. Il a surtout une conséquence méthodologique : aucune statistique globale n'étant estimée, aucune information ne peut fuir de l'ensemble d'entraînement vers l'ensemble de test par la normalisation. En contrepartie, l'information d'amplitude absolue est perdue, alors qu'elle caractérise partiellement le sommeil profond.

3.2.5.2 Le corpus produit


La préparation est assurée par un script exécuté une seule fois, dont le produit alimentera les douze entraînements du sprint suivant. Il prend en entrée les deux fichiers que la cohorte livre pour chaque nuit : l'enregistrement au format EDF, qui porte le signal, et un fichier XML d'annotations, qui porte le scoring de l'expert.

Du côté du signal, les cinq dérivation sont extraites sous leur nom exact, ramenées à 100 Hz par rééchantillonnage de Fourier, découpées en fenêtres de 3 000 échantillons et centrées-réduites par z-score. Du côté des annotations, chaque élément `ScoredEvent` de type « stades » donne un instant de début, une durée et un stade ; le script les projette sur la grille de 30 secondes, replie le stade 4 sur le N3 et comble les fenêtres restées vides par le dernier stade valide. Les deux flux sont ensuite alignés sur le plus court des deux, et les époques qu'aucun événement ne couvre sont écartées.

Le résultat est sérialisé dans un fichier `.pt` par sujet, qui contient le tenseur X de forme $(N, 5, 3\,000)$ en simple précision, le vecteur d'étiquettes y en entier court, l'identifiant du sujet et son nombre d'époques. C'est cette conversion qui rend l'entraînement possible sur le poste disponible. Seules les cinq dérivation utiles sont conservées, à 100 Hz plutôt qu'à la fréquence d'acquisition d'origine, et sans les voies respiratoires ni les canaux de service du montage : la nuit tombe à environ 60 Mo. Le format `y` est aussi pour quelque chose : le fichier est écrit exactement tel que le chargeur l'attend, si bien que les douze entraînements du sprint suivant relisent le corpus sans repayer le décodage EDF, le rééchantillonnage ni l'analyse du XML.

Le script est relançable : un sujet déjà converti est ignoré, ce qui permet d'étaler la campagne de préparation sur plusieurs sessions et de rejouer la préparation à l'identique.

Cent quatre-vingt-seize enregistrements de la cohorte SHHS1 [31] ont été retenus, pour un total de 195 130 époques de 30 secondes. Le corpus est filtré et non échantillonné : un sujet est écarté s'il lui manque une des cinq dérivation requises ou son fichier d'annotations. Les sujets retenus sont donc les premiers de la cohorte à satisfaire le montage complet, ce qui introduit un biais de sélection dont nous discuterons la portée.



corpus SHHS1 — 196 enregistrements, 195 130 époques de 30 secondes

FIGURE 18 Distribution des stades dans le corpus d'entraînement, aux deux granularités.

Le déséquilibre conditionne tout le sprint suivant. Le N2 occupe à lui seul 40,2 % des époques, tandis que le N1 n'en représente que 3,3 %, soit 6 361 exemples. Un modèle qui ignorerait purement et simplement cette classe perdrait à peine trois points d'exactitude globale, comportement que la pondération des classes doit empêcher.





3.2.5.3 Découpage et pondération

Le corpus est découpé en trois parts stratifiées sur la classe, dans les proportions 80 / 10 / 10, soit 156 104 époques d'entraînement et 19 513 pour chacun des ensembles de validation et de test. La pondération des classes est fixée à l'inverse de leur fréquence, puis renormalisée : le REM se voit attribuer un poids 4,4 fois supérieur à celui du NREM en trois classes, et le N1 un poids 12,3 fois supérieur à celui du N2 en cinq classes.

3.2.6 Revue du sprint

Ce premier sprint a produit le socle de tout le projet : une chaîne de préparation opérationnelle et un corpus de 195 130 époques étiquetées, issues de 196 enregistrements cliniques.

L'arbitrage de départ, travailler sur un jeu public pendant l'instruction de la demande d'accès, s'est révélé payant : lorsque les données définitives sont arrivées, la chaîne était éprouvée et il n'a suffi que de la rejouer à plus grande échelle.

Deux constats issus de ce sprint pèseront sur les suivants : le corpus est fortement déséquilibré, avec un stade N1 marginal, et il résulte d'un filtrage sur la complétude du montage plutôt que d'un tirage aléatoire. Le sprint suivant exploite ce corpus pour entraîner les trois familles d'architectures de classification.

3.3 Sprint 2 : Modèles de classification des stades

Le deuxième sprint est consacré à l'entraînement des modèles de classification. Le corpus produit au sprint précédent y est exploité pour entraîner trois familles d'architectures sur quatre configurations, soit douze modèles au total. Le sprint a été dominé par une contrainte matérielle qui a imposé un arbitrage explicite sur la quantité de données exploitable, et dont la portée conditionne la lecture de tous les résultats.

3.3.1 Objectif du sprint

L'objectif était de couvrir les trois familles d'architectures identifiées comme complémentaires dans l'étude préalable, sur les quatre configurations retenues : deux montages (cinq dérivations pour le laboratoire, deux pour l'ambulatoire) et deux granularités de sortie (trois stades pour la robustesse, cinq pour la conformité au référentiel AASM).

Ce plan factoriel répond à une question que la littérature laisse généralement ouverte : quelle est la part respective, dans la performance finale, de l'architecture du modèle, du nombre de dérivations disponibles et de la granularité demandée ? Entraîner les douze combinaisons permet d'y répondre par comparaison directe, sur un protocole identique.

3.3.2 Sprint Backlog

Le sprint a embarqué quatre récits pour 47 points de complexité (tableau 21).





ID	Module	Récit utilisateur	Tâches	Estim.
US-05	Corpus à l'échelle	En tant qu'ingénieur, je veux prétraiter les 196 enregistrements de la cohorte clinique	Rapatrier la cohorte après obtention de l'accès Rejouer la chaîne de préparation à l'échelle Contrôler la distribution des classes obtenue	8 pts
US-06	Réseau convolutif	En tant que système, je veux classer chaque époque avec un réseau convolutif multi-échelle	Concevoir les deux branches d'échelles distinctes Implémenter la boucle d'entraînement Entraîner les quatre variantes	13 pts
US-07	Réseau récurrent	En tant que système, je veux classer chaque époque avec un réseau récurrent à pooling attentionnel	Implémenter le réseau bidirectionnel à mémoire longue Ajouter le mécanisme d'attention temporelle Entraîner les quatre variantes	13 pts
US-08	Réseau attentionnel	En tant que système, je veux classer chaque époque avec un Transformer par patches	Découper l'époque en fragments et les projeter Ajouter le jeton de synthèse et l'encodage positionnel Entraîner les quatre variantes	13 pts

TABLE 21 Sprint Backlog — Sprint 2

3.3.3 Analyse

3.3.3.1 Diagramme des cas d'utilisation

Le cas d'utilisation de ce sprint reste porté par le moteur d'inférence (figure 19). Le praticien n'y accède pas directement : il en bénéficiera au sprint 4, dans la release 2, lorsque le service d'inférence sera exposé.






FIGURE 19 Diagramme des cas d'utilisation du sprint 2 — classification des stades

3.3.3.2 Description textuelle des cas d'utilisation

Titre	Classer une époque
Acteur	Moteur d'inférence
Description	Attribuer à une fenêtre de 30 secondes le stade de vigilance qui la caractérise, parmi trois ou cinq classes selon la configuration
Préconditions	Un tenseur d'époques normalisées est disponible ; le modèle correspondant à la configuration demandée est chargé
Scénario de base	1. Le système sélectionne le modèle correspondant au montage et à la granularité. 2. Il constitue des lots d'époques et les transfère au processeur graphique. 3. Le modèle produit un vecteur de scores par époque. 4. Le système retient la classe de score maximal. 5. Il restitue la séquence de stades pour l'enregistrement complet.
Scénario alternatif	• 1a — Le modèle demandé n'est pas disponible : l'opération est refusée avec un message explicite. • 2a — La mémoire du processeur graphique est insuffisante : le traitement bascule sur le processeur central.

TABLE 22 Description textuelle du cas « Classer une époque »





3.3.4 Conception

3.3.4.1 Diagramme de séquence objet

La figure 20 décrit la boucle d'entraînement d'un modèle.




FIGURE 20 Diagramme de séquence objet du sprint 2 — entraînement d'un modèle

La conception porte ensuite sur les trois architectures elles-mêmes, chacune pensée pour capter une facette différente du signal.

3.3.4.2 Réseau convolutif multi-échelle

Le premier modèle exploite une observation issue de l'étude préalable : les éléments graphiques du référentiel AASM vivent à des échelles temporelles différentes. Un fuseau du sommeil dure environ une demi-seconde et oscille autour de 12 à 14 hertz ; une onde lente s'étale sur plus d'une seconde. Un noyau de convolution unique ne peut capter les deux.

L'architecture retenue comporte donc deux branches parallèles appliquées au même signal (figure 21). La branche fine emploie un noyau de 50 échantillons, soit une demi-seconde, et la branche grossière un noyau de 200 échantillons, soit deux secondes. Leurs représentations sont concaténées avant classification.







FIGURE 21 Réseau convolutif à deux branches d'échelles temporelles distinctes.

3.3.4.3 Réseau récurrent à pooling attentionnel

Le deuxième modèle traite l'époque comme une séquence de 3 000 pas, chacun décrit par les dérivations disponibles. Un réseau récurrent bidirectionnel à mémoire longue [32], de deux couches de 128 unités, en produit une représentation contextualisée dans les deux sens du temps.

Se pose alors la question de la réduction : comment condenser 3 000 états en un vecteur unique ? Prendre le dernier état privilégierait la fin de la fenêtre ; en faire la moyenne diluerait un événement bref dans le reste. Nous employons un *pooling attentionnel* [33] : un petit réseau apprend à attribuer à chaque pas un poids, dont la somme vaut un, et la représentation finale est la moyenne pondérée des états (figure 22).



les poids d'attention indiquent les instants retenus

FIGURE 22 Réseau récurrent bidirectionnel à pooling attentionnel.

3.3.4.4 Réseau attentionnel par patches

Le troisième modèle abandonne la récurrence au profit de l'auto-attention [34]. L'époque est découpée en 60 fragments consécutifs de 50 échantillons, chacun projeté linéairement dans un espace de dimension 128. Un jeton de synthèse est ajouté en tête de séquence, et un encodage positionnel sinusoïdal réinjecte l'ordre temporel que l'auto-attention, par construction, ignore (figure 23).

Le découpage en fragments est ce qui rend l'approche viable. L'auto-attention a un coût quadratique en la longueur de séquence : l'appliquer aux 3 000 échantillons bruts demanderait neuf millions de coefficients par tête et par époque. Ramenée à 61 jetons, la même opération en demande moins de quatre mille.






FIGURE 23 *Modèle attentionnel : l'époque est traitée comme une suite de fragments.*

3.3.5 Réalisation

3.3.5.1 Stratégie d'entraînement sous contrainte matérielle

Dimensionnement du problème

Une époque de 30 secondes échantillonnée à 100 Hz sur cinq dérivations occupe 60 ko en simple précision. Rapporté à une cohorte entière, le corpus dépasse de plusieurs ordres de grandeur ce qu'une station de développement peut contenir (tableau 23).

Configuration	Sujets	Époques	Empreinte	Tient dans
2 dérivations	196	195 130	4,7 Go	mémoire vidéo et vive
5 dérivations	196	195 130	11,7 Go	mémoire vive seulement
5 dérivations, variante attentionnelle	150	148 958	8,9 Go	mémoire vive seulement
cohorte SHHS1 complète	5 793	≈ 5 800 000	≈ 346 Go	ni l'une ni l'autre

TABLE 23 Empreinte du corpus d'entraînement en simple précision

La cohorte complète représenterait environ 346 Go. Comme les fichiers préparés sont stockés exactement tels qu'ils seront chargés, ce chiffre vaut aussi bien pour le disque que pour la mémoire : la contrainte se manifeste deux fois, dès la préparation. La question porte donc sur la fraction à convertir et sur la façon de la faire circuler jusqu'au processeur graphique.





Trois stratégies de résidence des données

Stratégie	Principe	Limite	Décision
Tout en mémoire vidéo	Le corpus est transféré une fois sur le processeur graphique ; plus aucune copie pendant l'entraînement	Ne laisse pas de marge pour les activations et exclut d'emblée le protocole à cinq dérivations	écartée
Tout en mémoire vive	Le corpus réside dans la mémoire de l'hôte ; chaque lot est copié vers le processeur graphique en accès direct depuis une zone page-verrouillée	Plafonne le nombre de sujets ; empreinte doublée au moment du découpage	retenue
Lecture paresseuse	Chaque lot est relu sur disque à la volée ; l'empreinte mémoire devient négligeable	Le processeur graphique attend le disque à chaque itération	écartée

TABLE 24 Stratégies de résidence des données pendant l'entraînement

La lecture paresseuse aurait permis d'exploiter les 5 793 enregistrements, mais en affamant le processeur graphique : le temps par époque devient dominé par les entrées-sorties. Dans les quatre semaines du sprint, il aurait fallu descendre bien en dessous des trente époques d'entraînement nécessaires à la convergence, et cela pour douze variantes. Le modèle aurait vu davantage de patients, mais chacun beaucoup moins souvent, et aurait sous-appris.

Le choix inverse a été fait : restreindre la cohorte à 196 sujets pour que le corpus tienne intégralement en mémoire vive, et consacrer la totalité du budget de calcul à l'apprentissage plutôt qu'au transfert. Les 195 130 exemples étiquetés restent largement suffisants pour des architectures de quelques millions de paramètres, et les trente époques complètes ont pu être menées sur les douze variantes.

Portée de la contrainte

Onze carnets sur douze fixent la limite à 196 sujets. Le douzième, le modèle attentionnel à cinq dérivations et trois classes, descend à 150, soit 148 958 époques et 8,9 Go. Ce modèle matérialise soixante jetons de dimension 128 par époque, ainsi qu'une matrice d'attention par tête : ses activations débordaient là où les deux autres architectures passaient encore.

Cette réduction explique un écart dans les chiffres rapportés : le jeu de test de cette seule variante compte 14 896 époques au lieu de 19 513.

Réglages d'entraînement

Quatre réglages découlent directement de la contrainte mémoire. La précision mixte tient les activations en demi-précision et les accumulations en simple précision, avec mise à l'échelle des gradients : l'empreinte des activations est divisée par deux et les unités tensorielles y gagnent en débit. Les lots transitent par une zone de mémoire page-verrouillée, copiée en accès direct vers le processeur graphique pendant que le lot précédent est encore en calcul. Aucun processus de chargement parallèle n'est employé, car le corpus réside déjà en mémoire : un processus supplémentaire dupliquerait le tenseur de 11,7 Go sans rien précharger. Les segments extensibles de l'allocateur limitent enfin la fragmentation, qui provoquait des échecs d'allocation en fin d'entraînement.

Les autres réglages portent sur l'optimisation. L'optimiseur est AdamW, de pas initial 5×10^{-4} , qui découple la régularisation de l'adaptation du pas ; un recuit cosinus fait décroître ce pas jusqu'à 1×10^{-6} au fil des trente





époques. Le gradient est écrêté à 1,0, sans quoi les gradients du modèle récurrent explosent sur des séquences de 3 000 pas. Le point de contrôle retenu est celui qui maximise le κ de validation, et non celui qui minimise la perte : sur des classes aussi déséquilibrées, la perte peut s'améliorer pendant que la classe minoritaire se dégrade, ce que le κ de Cohen [35] ne laisse pas passer.

La figure 24 illustre le déroulement d'un entraînement. L'écart croissant entre les courbes d'entraînement et de validation traduit un surapprentissage progressif, que la sélection du meilleur point de contrôle sur le κ de validation neutralise en pratique.




FIGURE 24 Évolution de la perte, de l'exactitude et du κ de validation au cours des trente époques d'entraînement du modèle convolutif à cinq dérivations et trois classes.

3.3.5.2 Résultats

Les douze modèles

Configuration	Architecture	Exactitude	κ	F1 macro	F1 pondéré
5 dérivations, 3 classes	Convolutif	91,66 %	0,853	0,89	0,92
	Récurrent	90,86 %	0,843	0,89	0,91
	Attentionnel	90,14 %	0,826	0,87	0,90
2 dérivations, 3 classes	Convolutif	89,10 %	0,810	0,86	0,89
	Récurrent	87,58 %	0,790	0,84	0,88
	Attentionnel	86,92 %	0,771	0,83	0,87
5 dérivations, 5 classes	Convolutif	82,78 %	0,761	0,72	0,83
	Récurrent	78,60 %	0,713	0,71	0,80
	Attentionnel	81,55 %	0,742	0,70	0,81
2 dérivations, 5 classes	Convolutif	79,90 %	0,723	0,69	0,80
	Récurrent	76,01 %	0,679	0,68	0,78
	Attentionnel	77,15 %	0,686	0,66	0,77

TABLE 25 Performances des douze modèles de base sur le jeu de test

Trois enseignements se dégagent.

L'apport des dérivations oculaires et musculaires est net. À granularité constante, le passage de deux à cinq dérivations gagne entre 2,6 et 3,9 points d'exactitude. Ce résultat était attendu : l'électro-oculogramme et l'électro-myogramme portent précisément l'information qui distingue le sommeil paradoxal.





Le passage à cinq stades coûte cher. La même architecture perd entre 8,6 et 12,3 points en passant de trois à cinq classes.

Le convolutif domine, mais de peu. Il arrive en tête sur les quatre configurations. L'écart avec les deux autres architectures reste toutefois inférieur à quatre points, ce qui confirme qu'aucune famille ne domine franchement, et surtout que leurs erreurs ne sont pas identiques.

La figure 25 rend cette dernière affirmation visible : les trois matrices portent sur le même jeu de test, mais leurs erreurs ne se situent pas aux mêmes endroits. C'est cette complémentarité que l'empilement, au sprint suivant, exploitera.




FIGURE 25 Matrices de confusion des trois architectures, configuration à cinq dérivation et trois classes. *Effectifs bruts.*

Le problème du stade N1

	Classe	Précision	Rappel	F1	Effectif
3 classes	Éveil	0,94	0,92	0,93	5 990
	NREM	0,92	0,94	0,93	11 001
	REM	0,84	0,79	0,82	2 522
5 classes	Éveil	0,92	0,92	0,92	5 990
	N1	0,29	0,24	0,26	638
	N2	0,86	0,78	0,82	7 832
	N3	0,70	0,88	0,78	2 531
	REM	0,80	0,84	0,82	2 522

TABLE 26 Performances par classe — configuration à cinq dérivation

Le stade N1 est la seule classe véritablement échouée, avec un F1 de 0,26 pour le modèle convolutif. Les autres architectures ne font pas mieux (le récurrent atteint 0,30 et l'attentionnel 0,21), mais elles échouent différemment. Le récurrent affiche un rappel de 0,59 pour une précision de 0,20 : il sur-prédit massivement le N1. Le convolutif fait l'inverse, avec un rappel de 0,24 pour une précision de 0,29.

La figure 26 montre où partent les époques de N1 mal classées.






FIGURE 26 *Matrice de confusion du modèle convolutif à cinq dérivations et cinq classes. Effectifs bruts sur les 19 513 époques de test.*

Sur les 638 époques réellement en N1, 150 seulement sont reconnues. Les autres se dispersent : 233 sont versées en N2, 136 en éveil et 116 en sommeil paradoxal. Cette dispersion n'est pas un défaut d'apprentissage mais le reflet de la définition même du stade, un état de transition sans marqueur graphique propre. Le modèle le classe dans les états qui l'encadrent, ce que fait aussi un scoreur humain hésitant.

On observe par ailleurs une seconde confusion, de nature différente : 950 époques de N2 sont classées en N3. Celle-ci relève d'un seuil et non d'une ambiguïté : le référentiel AASM fixe le passage en N3 à 20 % d'ondes lentes dans la fenêtre, et une époque à 19 % est presque indiscernable d'une époque à 21 %.

3.3.6 Revue du sprint

Ce sprint a produit douze modèles de classification couvrant trois architectures, deux montages et deux granularités. La meilleure variante, le réseau convolutif à cinq dérivations et trois classes, atteint 91,66 % d'exactitude pour un κ de 0,853, au voisinage de l'accord inter-expert rapporté dans la littérature.

Le sprint a surtout imposé un arbitrage explicite : restreindre la cohorte pour maintenir le corpus en mémoire vive, et préserver ainsi la qualité de convergence plutôt que le volume de données. Cet arbitrage sera rediscuté dans la synthèse méthodologique du sprint suivant (section 4.2.5.4).

Enfin, l'analyse par classe a révélé que les trois architectures échouent différemment sur le stade N1. C'est la condition d'efficacité de la combinaison de modèles, que le sprint 3 met en œuvre en ouverture de la release suivante.

3.4 Revue de la release 1

3.4.1 Incrément livré

La release a livré l'intégralité de son backlog, soit 76 points en deux sprints. Le tableau 27 confronte l'incrément attendu à celui qui a été démontré à l'encadrement lors de la revue.





Élément attendu	Réalisation	État
Chaîne de préparation	Six étapes, du décodage du fichier EDF à la sérialisation en tenseurs ; script relançable	✓
Corpus d'apprentissage	195 130 époques étiquetées issues de 196 enregistrements SHHS1, découpées en 80 / 10 / 10	✓
Modèles de base	Douze modèles (trois architectures, deux montages, deux granularités) évalués sur un protocole identique	✓
Niveau de performance	Meilleure variante, convolutive à cinq dérivations et trois classes : 91,66 % d'exactitude pour un κ de 0,853	✓

TABLE 27 Revue de la release 1 : incrément attendu et incrément livré

3.4.2 Rétrospective

La rétrospective de la release a dégagé trois enseignements, qui ont orienté la planification de la suivante.

Occuper les délais externes plutôt que les subir. Le recours au jeu public Sleep-EDF pendant l'instruction de la demande d'accès a permis de disposer d'une chaîne éprouvée dès l'arrivée des données. Attendre l'autorisation aurait immobilisé le premier sprint tout entier.

Assumer la contrainte matérielle. La résidence intégrale du corpus en mémoire vive a imposé de restreindre la cohorte à 196 sujets. L'arbitrage a préservé la qualité de convergence des douze modèles, mais il borne la portée des résultats ; il est rediscuté dans la synthèse méthodologique de la release suivante (section 4.2.5.4).

Tirer parti de la complémentarité des erreurs. Les trois architectures échouent différemment, en particulier sur le stade N1. Ce constat a placé la combinaison des modèles en tête du backlog de la release suivante.

Conclusion

Cette première release a livré le moteur de classification de HYPNORIA : une chaîne de préparation éprouvée, un corpus de 195 130 époques étiquetées et douze modèles de base, dont le meilleur atteint un κ de 0,853, au voisinage de l'accord inter-expert rapporté dans la littérature.

Cet incrément reste toutefois invisible pour le praticien, et il se limite à la description du sommeil. La release suivante le prolonge vers le diagnostic, en combinant les modèles et en prédisant de manière explicable la sévérité du syndrome d'apnées, puis le rend accessible depuis un poste de travail sécurisé.





4 Release 2 : Diagnostic expliqué et poste de travail

Introduction

Ce chapitre présente la deuxième release, menée de la semaine 9 à la semaine 16. Là où la première a produit un moteur de classification, celle-ci livre la première version de HYPNORIA utilisable par un médecin : à partir d'un enregistrement brut, le praticien obtient l'hypnogramme, les métriques du sommeil et une prédiction de la sévérité du syndrome d'apnées accompagnée de ses facteurs explicatifs. Nous présentons l'objectif et le backlog de la release, détaillons ses deux sprints, puis en dressons la revue.

4.1 Présentation de la release

4.1.1 Objectif de la release

La deuxième release vise à livrer un produit minimum viable : le plus petit incrément qui apporte au praticien la valeur centrale du projet, à savoir un diagnostic expliqué. Elle réunit deux sprints de natures différentes. Le sprint 3 prolonge le travail de modélisation : il combine les modèles de base, construit le modèle de sévérité et son mécanisme d'explication. Le sprint 4 expose l'ensemble à travers une interface applicative sécurisée et un poste de travail guidé.

Pris isolément, aucun de ces deux sprints ne constitue une version livrable : des modèles sans interface ne servent pas le praticien, et une interface sans modèle de sévérité ne délivre pas le diagnostic attendu. C'est leur réunion qui forme l'incrément de la release.

4.1.2 Backlog de la release

La release regroupe vingt récits issus de cinq épics (authentification, classification, sévérité du SAOS, visualisation et export), pour 122 points de complexité (tableau 28).

Sprint	Période	Objectif du sprint	Récits	Pts
Sprint 3	23 mars – 19 avr.	Faire coopérer les architectures, puis prédire de manière explicable la sévérité du SAOS	US-13 à 16	42
Sprint 4	20 avr. – 17 mai	Rendre les modèles consommables et offrir au praticien un parcours d'analyse guidé	US-09 à 12, 17 à 23, 26 à 29, 40	80
Total de la release			20 récits	122

TABLE 28 Backlog de la release 2

L'incrément attendu en fin de release est un parcours complet, de l'authentification du praticien jusqu'au rapport de sévérité expliqué, reposant sur quatre ensembles de classification et sur un modèle de sévérité.





4.2 Sprint 3 : Ensembles et prédiction de la sévérité

Premier sprint de la release, le sprint 3 articule deux travaux complémentaires. Le premier fait coopérer les modèles de la release précédente par un mécanisme d'empilement. Le second franchit un pas supplémentaire : passer de la description du sommeil au *diagnostic*, en prédisant la sévérité d'un syndrome d'apnées à partir de l'hypnogramme produit, et en expliquant chaque prédiction. Le sprint se conclut sur une synthèse méthodologique qui discute les limites de l'ensemble des résultats obtenus depuis le sprint 1.

4.2.1 Objectif du sprint

Le sprint poursuivait trois objectifs.

Le premier était de tirer parti de la complémentarité des architectures mise en évidence au sprint 2. Les trois familles échouent différemment, notamment sur le stade N1 : c'est la condition d'efficacité d'une combinaison de modèles.

Le deuxième était d'exploiter l'hypnogramme comme marqueur indirect du syndrome d'apnées. L'hypothèse est que les micro-éveils répétés provoqués par les obstructions laissent une empreinte mesurable sur l'architecture du sommeil, indépendamment des capteurs respiratoires.

Le troisième était de rendre chaque prédiction explicable, condition d'usage clinique posée dès le chapitre 1.

4.2.2 Sprint Backlog

Le sprint a embarqué quatre récits pour 42 points de complexité (tableau 29).





ID	Module	Récit utilisateur	Tâches	Estim.
US-13	Ensembles	En tant que système, je veux combiner les trois modèles par un méta-apprenant	Collecter les probabilités sur un jeu de validation par sujets Entraîner une régression logistique équilibrée Comparer au vote moyen et au meilleur modèle isolé	13 pts
US-14	Marqueurs du sommeil	En tant que système, je veux extraire les marqueurs d'architecture du sommeil depuis l'hypnogramme	Analyser les hypnogrammes de la seconde visite Calculer 25 marqueurs conformes au référentiel AASM Construire 8 variables d'interaction	8 pts
US-15	Prédiction de sévérité	En tant que système, je veux prédire la sévérité du SAOS en quatre classes	Écarter les variables qui fuient la cible Comparer six familles de classifieurs en validation croisée Empiler les trois meilleurs vers un méta-apprenant	13 pts
US-16	Explicabilité	En tant que médecin, je veux connaître les facteurs aggravants et protecteurs de la prédiction	Calculer les attributions par valeurs de Shapley Trier et restituer les dix facteurs dominants Séparer contributions positives et négatives	8 pts

TABLE 29 Sprint Backlog — Sprint 3





4.2.3 Analyse

4.2.3.1 Diagramme des cas d'utilisation




FIGURE 27 Diagramme des cas d'utilisation du sprint 3 — diagnostic et explication





4.2.3.2 Description textuelle des cas d'utilisation

Titre	Prédire la sévérité du SAOS
Acteurs	Médecin du sommeil, moteur d'inférence
Description	Estimer le niveau de sévérité du syndrome d'apnées obstructives à partir de l'architecture du sommeil et de marqueurs cliniques, et exposer les facteurs qui déterminent cette estimation
Préconditions	Une séquence de stades est disponible, issue d'une analyse ou d'une saisie manuelle
Scénario de base	1. Le système extrait les marqueurs d'architecture depuis l'hypno-gramme. 2. Le médecin complète les données démographiques et oxymétriques. 3. Il déclenche l'évaluation du risque. 4. Le système construit le vecteur de variables et comble les valeurs absentes. 5. Le moteur produit la classe de sévérité et ses probabilités. 6. Le système calcule les contributions de chaque variable. 7. Le système affiche la sévérité, les facteurs aggravants et protecteurs, et l'interprétation clinique.
Scénario alternatif	• 2a — Le médecin importe un rapport externe : le système en extrait les valeurs et préremplit le formulaire. • 4a — Des variables cliniques manquent : le système applique la médiane de la population d'apprentissage et le signale. • 5a — Les modèles ne sont pas chargés : l'opération est refusée avec un message explicite.

TABLE 30 Description textuelle du cas « Prédire la sévérité du SAOS »





4.2.4 Conception

4.2.4.1 Diagramme de séquence objet




FIGURE 28 Prédiction de la sévérité et production des facteurs explicatifs.

4.2.5 Réalisation

4.2.5.1 Combinaison des modèles par empilement

Principe

L'*empilement*, introduit par Wolpert [36], consiste à entraîner un second modèle, le *méta-apprenant*, à combiner les sorties de plusieurs modèles de base. Contrairement au vote majoritaire, qui accorde le même poids à tous, le méta-apprenant *apprend* à qui faire confiance et dans quelles circonstances (figure 29).






FIGURE 29 Principe de l'empilement : trois modèles hétérogènes produisent des vecteurs de probabilités, qu'un méta-apprenant apprend à combiner.

Chaque modèle produit un vecteur de probabilités sur les K classes ; les trois vecteurs sont concaténés en $3K$ méta-caractéristiques qui alimentent une régression logistique équilibrée. Le choix d'un modèle linéaire pour le second niveau est délibéré : le méta-apprenant dispose de peu de variables et doit avant tout produire des probabilités calibrées, ce qu'un modèle simple fait mieux qu'un réseau supplémentaire [37].

Le point critique est le jeu sur lequel le méta-apprenant est entraîné. L'entraîner sur les sorties produites par les modèles de base *sur leurs propres données d'entraînement* fausserait l'apprentissage : ces sorties sont anormalement bonnes, et le méta-apprenant apprendrait une confiance injustifiée. Les probabilités ont donc été collectées sur un jeu de validation constitué par découpage au niveau des sujets.

Résultats

Quatre ensembles ont été construits, un par configuration.

Configuration	Conv.	Réc.	Att.	Vote moyen	Empilement	Gain
5 dérivations, 3 classes	0,932	0,875	0,944	0,950	0,947	-0,003
2 dérivations, 3 classes	0,863	0,821	0,918	0,917	0,924	+0,006
5 dérivations, 5 classes	0,875	0,754	0,887	0,894	0,899	+0,005
2 dérivations, 5 classes	0,819	0,695	0,815	0,834	0,839	+0,005

de Cohen sur le jeu de test par sujets. Le gain est mesuré par rapport au vote moyen.

TABLE 31 Ensembles par empilement, comparés aux modèles de base et au vote moyen

Ces résultats appellent une lecture nuancée. L'empilement dépasse le meilleur modèle isolé sur les quatre configurations, ce qui valide le principe. Mais il ne dépasse le vote moyen que sur trois configurations sur quatre : sur la variante à cinq dérivations et trois classes, la moyenne arithmétique des probabilités fait légèrement mieux que le méta-apprenant.

L'explication tient à la taille du jeu d'apprentissage du second niveau. Le méta-apprenant est entraîné sur une vingtaine de milliers d'exemples décrits par neuf variables seulement. Lorsque les trois modèles de base sont déjà très concordants, ce qui est le cas dans la configuration la plus favorable, il ne reste presque rien à apprendre, et la pondération estimée n'apporte pas davantage qu'une moyenne uniforme.





Rapporter seulement le gain sur le meilleur modèle isolé aurait donné de l'empilement une image trop favorable. La comparaison au vote moyen, souvent omise dans la littérature, montre que son apport est réel mais modeste, et qu'il dépend du degré de désaccord entre les modèles combinés.




FIGURE 30 Comparaison des κ obtenus par les modèles de base, le vote moyen et l'empilement, pour la configuration à cinq dérivationes et cinq classes.




FIGURE 31 Matrice de confusion de l'ensemble à cinq dérivationes et trois classes, sur les 20 314 époques du jeu de test par sujets.

4.2.5.2 Prédiction de la sévérité du syndrome d'apnées

Positionnement

Le dépistage du syndrome d'apnées repose classiquement sur des questionnaires cliniques ou sur l'analyse de signaux respiratoires. Le tableau 32 situe notre approche parmi ces familles.





Approche	Entrées	Atouts	Limites
Questionnaires (Berlin, STOP-BANG)	Anamnèse, anthropométrie	Immédiat, sans matériel	Spécificité faible, pas de sévérité
Oxymétrie nocturne	Saturation en oxygène	Matériel léger, bon dépistage	Sévérité imprécise
Signaux respiratoires et cardiaques	Flux nasal, sangles, ECG	Performances élevées	Exige les capteurs respiratoires
Architecture du sommeil (voie retenue)	Hypnogramme, oxymétrie sommaire, index d'éveil	Réutilise l'étage de staging ; marqueurs cliniquement lisibles	Marqueur indirect

TABLE 32 Approches d'évaluation du risque de SAOS

Construction de la matrice de variables

Les marqueurs d'architecture ont été extraits de 2 647 hypnogrammes de la seconde visite de la cohorte, puis complétés des variables cliniques et de variables d'interaction, pour un total de 53 variables. Le jeu a été partagé en 80 % d'apprentissage et 20 % de test, soit 530 sujets de test, avec stratification sur la classe de sévérité.

La figure 32 décrit l'enchaînement complet.




FIGURE 32 Chaîne de prédiction de la sévérité, de l'hypnogramme à l'explication.

Deux précautions méthodologiques ont été prises. Les index de perturbation respiratoire ont été exclus des variables d'entrée : ils mesurent directement les événements dont on cherche à prédire la sévérité, et les conserver aurait produit un modèle excellent mais dépourvu de valeur pratique. Par ailleurs, les modèles sensibles à l'échelle ont été encapsulés avec leur normaliseur dans un pipeline, de sorte que celui-ci soit ajusté sur chaque pli d'entraînement seulement et jamais sur le pli d'évaluation.

La figure 33 montre comment quelques marqueurs se comportent selon la classe de sévérité. On y lit à la fois la validité de l'hypothèse de départ (l'efficacité du sommeil décroît et l'index de fragmentation croît avec la sévérité) et la difficulté de la tâche : les distributions des classes normale et légère se recouvrent presque entièrement.






FIGURE 33 Distribution de huit marqueurs d'architecture du sommeil selon la classe de sévérité, sur la cohorte SHHS2.

Comparaison des classifieurs

Six familles ont été comparées en validation croisée stratifiée à cinq plis, sur le F1 macro.




FIGURE 34 F1 macro en validation croisée à cinq plis. La forêt aléatoire arrive en tête, suivie des deux implémentations de gradient boosté.

La forêt aléatoire [38] obtient le meilleur score (0,558), suivie de près par XGBoost [24] (0,552) et LightGBM [25] (0,544). Le perceptron multicouche (0,522), la machine à vecteurs de support (0,492) et les plus proches voisins (0,456) suivent. Les trois premiers ont été retenus comme modèles de base de l'ensemble.





Résultats sur le jeu de test

Modèle	Exactitude	κ	F1 macro	Écart ≤ 1 classe
Forêt aléatoire	57,0 %	0,409	0,576	95,5 %
Empilement	54,5 %	0,389	0,558	95,3 %
Référence : classe majoritaire	36,2 %	0,000	0,133	—

TABLE 33 Prédiction de la sévérité — résultats sur les 530 sujets de test

Trois observations se dégagent de ces résultats.

L'empilement n'apporte rien ici. Contrairement au cas de la classification des stades, il fait légèrement *moins* bien que la meilleure ligne de base. Ce résultat négatif est cohérent avec la condition de diversité : les trois modèles retenus sont tous des ensembles d'arbres, entraînés sur les mêmes variables. Leurs erreurs se recouvrent largement, et la combinaison n'a rien à corriger. Retenir la forêt aléatoire seule serait ici le choix rationnel.

La tâche est intrinsèquement difficile. Une exactitude de 57 % sur quatre classes peut sembler faible, mais la référence par la classe majoritaire n'est que de 36,2 %, et le κ de 0,41 correspond à un accord modéré. La difficulté vient de la nature même des seuils : un index d'apnées de 4,9 et un index de 5,1 classent deux patients différemment alors que rien ne les distingue physiologiquement.

L'erreur est presque toujours de faible amplitude. Plus de 95 % des prédictions tombent dans la bonne classe ou dans une classe adjacente. C'est la statistique cliniquement pertinente : le système se trompe rarement de plus d'un cran de sévérité, et n'annonce quasiment jamais un patient sévère comme normal.

	Normal	Léger	Modéré	Sévère
Normal	83	38	3	2
Léger	39	109	35	9
Modéré	4	47	54	22
Sévère	0	6	23	56

FIGURE 35 Matrice de confusion de la forêt aléatoire sur les 530 sujets de test. L'intensité est proportionnée à l'effectif de chaque classe réelle.

La lecture confirme le diagnostic. Les 192 sujets légers se répartissent presque également entre les trois premières classes : c'est là que se concentre l'erreur. À l'inverse, aucun sujet sévère n'est classé normal, et un seul sujet normal est classé sévère.







FIGURE 36 Courbes ROC en un-contre-tous, meilleure ligne de base et ensemble.

Avertissement sur les étiquettes. Les figures produites par le script d'origine portaient des étiquettes d'axes erronées : l'encodeur de classes les trie par ordre alphabétique, si bien que l'ordre effectif des indices est *Léger*, *Modéré*, *Normal*, *Sévère* et non l'ordre de sévérité utilisé dans le code. Le défaut ne touchait que l'affichage (les prédictions du système sont correctes) mais il a été corrigé dans le script, et les matrices présentées ici ont été recalculées avec l'ordre exact.

4.2.5.3 Explicabilité des prédictions

Choix de la méthode

Les méthodes d'explication se répartissent selon plusieurs axes (figure 37). Notre besoin est précis : expliquer une prédiction unique (explication locale), pour un modèle d'ensemble (méthode agnostique ou spécifique aux arbres), de manière exacte et reproductible.



la méthode encadrée en rouge est celle retenue dans ce travail

FIGURE 37 Taxonomie des principales méthodes d'explication, selon leur dépendance à l'architecture du modèle.

Les valeurs de Shapley [43], transposées à l'apprentissage automatique par SHAP [26], répondent à ce cahier des charges. Elles décomposent la prédiction en contributions additives par variable, avec des propriétés d'unicité





démontrées. Leur variante dédiée aux arbres [27] les calcule en temps polynomial plutôt qu'exponentiel, ce qui les rend applicables en production.




FIGURE 38 Lecture en cascade d'une explication SHAP : la propriété d'additivité relie la valeur de base à la prédiction individuelle.

Mise en œuvre et résultats

Les attributions sont calculées sur le modèle à gradient boosté, puis triées par contribution absolue décroissante. Les dix variables dominantes sont restituées au praticien, séparées en facteurs aggravants et protecteurs.






FIGURE 39 Importance des variables du modèle de sévérité, mesurée par le gain.

Les variables les plus influentes relèvent de l'oxymétrie et des index d'éveil, ce qui est physiologiquement cohérent : ce sont les conséquences les plus directes des événements respiratoires. Les marqueurs d'architecture du sommeil (fragmentation, proportion de sommeil profond, durée d'éveil intra-sommeil) viennent ensuite et apportent l'information complémentaire qui justifie la démarche.

Ces attributions expliquent le *modèle*, non le *phénomène*. Une contribution élevée signale une forte influence sur la prédiction, en aucun cas un lien de causalité. Le compte rendu remis au praticien porte cette mention.

Un second point tient à la méthode : la prédiction est rendue par un ensemble hétérogène, mais l'explication est calculée sur un modèle à arbres entraîné sur les mêmes données. Ce dédoublement permet d'obtenir des attributions exactes en temps polynomial, là où expliquer directement l'ensemble aurait imposé une approximation par échantillonnage. L'explication décrit donc un modèle très proche du modèle décisionnel, non ce modèle lui-même.

4.2.5.4 Synthèse méthodologique

Trois limites affectent la portée des résultats obtenus depuis le sprint 1.

Un découpage au niveau des époques. Les douze modèles de base ont été évalués sur un découpage aléatoire des 195 130 fenêtres, sans tenir compte du sujet dont elles proviennent. Comme chaque sujet contribue environ un millier d'époques, dont 80 % atterrissent dans l'ensemble d'entraînement, le modèle a vu, pour presque chaque époque de test, d'autres époques du même patient et de la même nuit. Les métriques mesurent donc la capacité à classer *une époque inconnue d'un patient connu*, et non *un patient inconnu*.

Deux protocoles non comparables. Les ensembles, eux, ont été évalués sur un découpage par sujets. Il en résulte que les valeurs du tableau 31 et celles du tableau 25 ne sont pas directement comparables. Le mémoire ne présente donc pas le passage de 91,66 % à 96,93 % comme un gain de l'empilement, car ce serait une comparaison invalide.





Plus gênant : les modèles de base ayant été entraînés sur un découpage par époques, ils avaient déjà rencontré des fenêtres appartenant aux sujets que le protocole d’empilement considère comme non vus.

Un corpus restreint et filtré. Le sous-corpus de 196 sujets représente 3,4 % de la cohorte disponible, et il a été constitué par filtrage sur la complétude du montage plutôt que par tirage aléatoire.

Ces trois limites se renforcent mutuellement et pointent vers un même correctif : une ré-évaluation complète sur un découpage par sujets unique, appliqué de façon identique aux modèles de base et aux ensembles. Ce travail, qui ne nécessite aucune modification des architectures, constitue la première des perspectives.

4.2.6 Revue du sprint

Ce sprint a produit les quatre ensembles de classification et le modèle de prédiction de sévérité, accompagné de son mécanisme d’explication.

Deux résultats nuancés en ressortent. L’empilement dépasse le meilleur modèle isolé sur les quatre configurations de classification, mais ne dépasse le vote moyen que sur trois d’entre elles. Et sur la prédiction de sévérité, il *dégrade* légèrement la meilleure ligne de base, faute de diversité entre trois modèles tous fondés sur des arbres.

Le modèle de sévérité atteint 57,0 % d’exactitude sur quatre classes, avec plus de 95 % des prédictions dans la bonne classe ou une classe adjacente, la statistique qui compte cliniquement.

Les modèles sont désormais complets. Le sprint suivant les expose à travers une interface applicative et un poste de travail utilisable par un praticien.

4.3 Sprint 4 : Service d’inférence et poste de travail

Les trois premiers sprints ont produit des modèles. Ce quatrième sprint, qui clôt la release, les rend utilisables : il expose une interface applicative sécurisée et construit le poste de travail du praticien, depuis le dépôt d’un enregistrement jusqu’au rapport de sévérité expliqué.

4.3.1 Objectif du sprint

L’objectif était de franchir le pas du *carnet d’expérimentation* vers le *service*. Trois exigences le structuraient.

La première était la disponibilité des modèles. Chargés naïvement à chaque requête, les modèles imposeraient plusieurs secondes de latence : ils devaient donc être conservés en mémoire entre deux appels.

La deuxième était la sécurisation des accès. Une plateforme manipulant des données de santé ne peut être ouverte : authentification, jetons signés et cloisonnement des rôles devaient être posés dès ce sprint.

La troisième était l’ergonomie du parcours. Une analyse dure plusieurs dizaines de secondes ; l’interface devait guider le praticien et le tenir informé sans jamais le laisser devant un écran muet.

4.3.2 Sprint Backlog

Le sprint a embarqué seize récits pour 80 points de complexité (tableau 34).





ID	Module	Récit utilisateur	Tâches	Estim.
US-26 à 29	Authentification	En tant qu'utilisateur, je veux me connecter et accéder aux fonctions de mon rôle	Hacher les mots de passe avec sel aléatoire Délivrer un jeton signé à expiration Vérifier le rôle sur chaque route protégée	15 pts
US-09 à 12	Service d'inférence	En tant que médecin, je veux lancer une analyse en choisissant la configuration adaptée à mon montage	Exposer les routes d'analyse et d'inspection Mettre les modèles en cache mémoire Calculer les métriques AASM	19 pts
US-17 à 20	Rapport de sévérité	En tant que médecin, je veux saisir les données cliniques et obtenir un rapport expliqué	Créer le formulaire clinique Analyser les rapports externes importés Produire l'interprétation automatique	23 pts
US-21 à 23	Visualisation	En tant que médecin, je veux visualiser l'hypnogramme et suivre la progression de l'analyse	Tracer l'hypnogramme interactif Superposer saturation et densité d'événements Afficher l'écran de progression	18 pts
US-40	Export	En tant que médecin, je veux exporter les marqueurs	Produire les exports tabulaire et balisé	5 pts

calculés
TABLE 34 Sprint Backlog — Sprint 4





4.3.3 Analyse

4.3.3.1 Diagramme des cas d'utilisation




FIGURE 40 Diagramme des cas d'utilisation du sprint 4 — poste de travail du médecin





4.3.3.2 Description textuelle des cas d'utilisation

Titre	Analyser un enregistrement
Acteurs	Médecin du sommeil, moteur d'inférence
Description	Produire l'hypnogramme et les métriques d'une nuit à partir d'un fichier d'enregistrement brut
Préconditions	Le médecin est authentifié; sa licence est valide; il dispose d'un fichier au format EDF
Scénario de base	1. Le médecin choisit le montage disponible, à deux ou cinq dériva-tions. 2. Il choisit la granularité de classification, à trois ou cinq stades. 3. Il dépose le fichier d'enregistrement. 4. Le système décode le fichier, résout les dériva-tions et prétraite le signal. 5. Le moteur classe chaque époque et le système calcule les mé-triques. 6. Le système affiche l'hypnogramme, les métriques et les alertes cliniques.
Scénario alternatif	• 3a — Le fichier n'est pas au format attendu : le dépôt est refusé. • 4a — Une dérivation est absente : repli documenté, l'analyse aboutit. • 4b — L'enregistrement est trop court : interruption avec message.

TABLE 35 Description textuelle du cas « Analyser un enregistrement »

4.3.4 Conception

4.3.4.1 Diagrammes de séquence objet

Les figures 41 et 42 décrivent les deux enchaînements structurants du sprint : l'ouverture de session et l'analyse d'un enregistrement.






FIGURE 41 Ouverture de session et délivrance du jeton.






FIGURE 42 Analyse d'un enregistrement : les résultats précèdent l'archivage.

La particularité de cet enchaînement tient à l'ordre des opérations : les résultats sont affichés au praticien *avant* que l'archivage du fichier, mis en place au sprint suivant, ne soit terminé.

4.3.5 Réalisation

4.3.5.1 Organisation de l'interface applicative

L'interface applicative est bâtie sur FastAPI, choisi pour son modèle asynchrone, sa validation déclarative des données et la génération automatique de sa documentation. Le code est réparti en modules à responsabilité unique.





Module	Lignes	Responsabilité
main.py	695	Point d'entrée, routes métier et d'administration, migration au démarrage, journalisation
ml_routes.py	984	Routes d'inférence : analyse, extraction de marqueurs, prédiction de sévérité, lecture de fichiers externes
ml_models.py	117	Définition des trois architectures de réseaux
preprocessing.py	199	Décodage EDF, résolution des dérivations, calcul des métriques AASM
osa_predictor.py	113	Chargement des modèles de sévérité, prédiction et attribution des contributions
db_models.py	113	Modèle de données et relations
schemas.py	163	Schémas de validation des entrées et sorties
auth.py	51	Jetons, empreintes de mots de passe, dépendance d'authentification
b2_storage.py	121	Client de stockage objet, dépôt et signature des liens
database.py	19	Connexion et session

TABLE 36 Modules de l'interface applicative

Deux mécanismes transversaux sont à signaler. Le premier est la migration au démarrage : le schéma ayant évolué au fil des sprints, l'application exécute à son lancement une série d'ajouts de colonnes conditionnels, ce qui permet de déployer une nouvelle version sur une base existante sans intervention manuelle. Le second est la signature des liens à la sérialisation, développée au sprint suivant.

4.3.5.2 Points d'entrée

L'interface expose trente-six routes réparties en six domaines. L'authentification en compte deux : `/token` délivre le jeton, `/users/me` renvoie le profil de l'appelant. L'administration en compte neuf, toutes réservées au rôle administrateur, qui couvrent le cycle de vie des comptes médecins et la réinitialisation de leur mot de passe, les établissements, les statistiques globales, et le journal d'audit avec son export.

Quatre routes servent le registre des patients et huit les examens, toutes réservées au rôle médecin : création et mise à jour d'un examen, dépôt de l'enregistrement brut, de l'hypnogramme, de sa version annotée et du compte rendu de sévérité, puis les annotations portées à l'époque. Six autres portent la collaboration, de l'annuaire des confrères aux messages d'un fil.

Les sept dernières sont celles du service de modèles : contrôle de santé, inspection des canaux d'un fichier, analyse d'un enregistrement, extraction des marqueurs, prédiction de la sévérité dans ses deux variantes et lecture d'un rapport externe. La documentation OpenAPI correspondante est produite automatiquement (figure 43).

La version livrée présente ici une faiblesse : les routes d'inférence ne sont pas protégées par le contrôle d'accès. Ce choix, initialement fait pour faciliter les essais pendant la mise au point, n'a pas été rétabli. Un appelant non authentifié peut donc soumettre un enregistrement à l'analyse. Aucune donnée patient n'est exposée (ces routes ne lisent ni n'écrivent en base) mais elles consomment des ressources de calcul. L'ajout de la dépendance d'authentification, qui tient en une ligne par route, figure parmi les corrections à apporter avant toute mise en service réelle.






FIGURE 43 Documentation OpenAPI générée automatiquement

4.3.5.3 Sécurité des accès

Mécanisme	Principe	Menace couverte
Empreintes de mots de passe	Fonction de dérivation lente avec sel aléatoire par compte	Compromission de la base : les mots de passe restent inexploitable
Jetons signés	Jeton porteur signé, transmis à chaque appel, contenant l'identité et le rôle	Usurpation : toute altération invalide la signature
Contrôle d'accès par rôle	Vérification du rôle et de la propriété de la ressource sur chaque route protégée	Élévation de privilège et accès aux patients d'un confrère
Liens d'accès signés	Les références de fichiers sont converties en URL signées valables 24 heures	Fuite de données : aucun objet n'est accessible sans signature valide

TABLE 37 Mécanismes de sécurité et menaces couvertes

Les mots de passe sont hachés par bcrypt, dont le sel aléatoire par compte interdit les tables précalculées. Les jetons sont signés en HMAC-SHA256 et portent l'adresse de l'utilisateur, son rôle et une date d'expiration fixée à sept jours. Le contrôle d'accès superpose deux niveaux : le rôle est vérifié en tête de route, la propriété de la ressource l'est ensuite.

4.3.5.4 Poste de travail du praticien

L'interface est une application monopage React, construite par Vite, organisée en composants regroupés par domaine fonctionnel.





Composant	Lignes	Rôle
AnalysisResults	1134	Restitution complète : hypnogramme, métriques, marqueurs, formulaire clinique, rapport de sévérité
PatientList	993	Registre des patients, historique des examens, documents archivés
CustomOSA	658	Prédiction à partir d'une saisie manuelle ou d'un rapport importé
Hypnogram	552	Tracé interactif de l'hypnogramme, de la saturation et de la densité d'événements
DoctorList	539	Administration des comptes et des licences
DeveloperPipeline	497	Visualisation de la chaîne de traitement
LandingPage	406	Page publique et authentification
AnalysisWizard	428	Assistant d'analyse en quatre étapes
HospitalsDashboard	233	Gestion des établissements
ConsultationsView	198	Boîte de réception des sollicitations
AuditLogsDashboard	194	Consultation et export du journal
CollaborationChat	171	Fil de discussion rattaché à un examen

TABLE 38 Principaux composants de l'interface

Le parcours principal se déroule en quatre étapes : le praticien déclare le montage disponible, puis la granularité souhaitée, dépose le fichier, et consulte les résultats. Chaque étape n'expose qu'une seule décision, assortie d'une recommandation par défaut.




FIGURE 44 Assistant d'analyse, étape 1 : déclaration du montage






FIGURE 45 Assistant d'analyse, étape 2 : granularité de classification

Pendant le traitement, un écran de progression affiche les tracés physiologiques et détaille les cinq étapes du pipeline. Ce retour visuel a une fonction précise : une interface muette pendant plusieurs dizaines de secondes laisserait croire à un blocage.



FIGURE 46 Écran de progression du traitement

La page de résultats superpose sur un même axe temporel l'hypnogramme prédit, la courbe de saturation et la densité d'événements respiratoires. Cette superposition est le choix de visualisation le plus utile de l'interface : elle permet de constater directement qu'une désaturation coïncide avec une sortie de sommeil paradoxal, ce que trois graphiques séparés ne montreraient pas.



FIGURE 47 Restitution des résultats d'analyse

Un second parcours permet une prédiction sans enregistrement, à partir d'une saisie manuelle ou d'un rapport externe importé. Cette voie répond à un usage réel : disposer d'un compte rendu produit par un autre laboratoire sans avoir accès au signal brut.






FIGURE 48 Prédiction de sévérité à partir d'une saisie manuelle

4.3.6 Revue du sprint

Ce sprint a transformé des modèles de laboratoire en un service utilisable. L'interface applicative expose les routes d'inférence, conserve les modèles en mémoire et protège les routes métier par un double contrôle de rôle et de propriété. Le poste de travail guide l'analyse en quatre décisions et restitue les résultats sur un axe temporel unique.

Une faiblesse a été identifiée et documentée : les routes d'inférence ne sont pas authentifiées.

4.4 Revue de la release 2

4.4.1 Incrément livré

La release a livré ses 122 points en deux sprints, dont 80 pour le seul sprint 4. L'incrément démontré lors de la revue est récapitulé au tableau 39.

Élément attendu	Réalisation	État
Ensembles de classification	Quatre ensembles par empilement, supérieurs au meilleur modèle isolé sur les quatre configurations	✓
Modèle de sévérité	Quatre classes, 53 variables : 57,0 % d'exactitude et plus de 95 % des prédictions à un cran près	✓
Explication des prédictions	Attributions par valeurs de Shapley, restituées en facteurs aggravants et protecteurs	✓
Interface applicative	Jetons signés, contrôle des rôles, modèles conservés en mémoire ; routes d'inférence non authentifiées	avec réserve
Poste de travail	Assistant d'analyse en quatre étapes, restitution sur un axe temporel unique, prédiction sans enregistrement	✓

TABLE 39 Revue de la release 2 : incrément attendu et incrément livré

4.4.2 Rétrospective

La rétrospective de la release a retenu trois enseignements.

Comparer à la bonne référence. Confronter l'empilement au vote moyen, et pas seulement au meilleur modèle isolé, a montré que son apport est réel mais modeste. Sur la prédiction de sévérité, il dégrade même légèrement la meilleure ligne de base, faute de diversité entre les modèles combinés.





Unifier les protocoles d'évaluation. La synthèse méthodologique du sprint 3 a établi que modèles de base et ensembles n'ont pas été évalués sur le même découpage. La correction, une ré-évaluation sur un découpage par sujets unique, ne touche aucune architecture ; elle constitue la première des perspectives du projet.

Documenter la dette technique. Les routes d'inférence, laissées ouvertes pour faciliter la mise au point, n'ont pas été protégées par le contrôle d'accès. La faiblesse est identifiée, et sa correction, d'une ligne par route, figure parmi les préalables à toute mise en service.

Conclusion

La deuxième release a livré la première version de HYPNORIA exploitable par un praticien. Les modèles de classification coopèrent au sein de quatre ensembles, la sévérité du syndrome d'apnées est prédite en quatre classes et chaque prédiction est accompagnée de ses facteurs explicatifs ; le tout est accessible depuis un poste de travail qui guide l'analyse en quatre décisions.

Il manque cependant à cet outil ce qui en ferait un système d'information clinique : la mémoire des patients et de leurs examens, la gouvernance des accès et les moyens du travail à plusieurs. C'est l'objet de la troisième et dernière release.





5 Release 3 : Plateforme clinique et industrialisation

Introduction

Ce chapitre présente la troisième et dernière release, menée de la semaine 17 à la semaine 24. Elle transforme l'outil d'analyse livré par la release précédente en une plateforme clinique complète : dossier patient persistant, archivage sécurisé, gouvernance multi-établissements, collaboration entre praticiens, restitution documentaire et déploiement reproductible. Comme les précédents, le chapitre présente la release, détaille ses deux sprints et en dresse la revue.

5.1 Présentation de la release

5.1.1 Objectif de la release

La troisième release vise à livrer une plateforme prête à être déployée en contexte clinique. Les fonctions d'analyse ne changent plus ; ce qui s'ajoute, c'est tout ce qui permet de les exploiter durablement, à plusieurs et en confiance. Le sprint 5 dote la plateforme d'une mémoire et d'une gouvernance ; le sprint 6 couvre la collaboration, la production du compte rendu et l'industrialisation du déploiement.

5.1.2 Backlog de la release

Avec trente-deux récits et 160 points de complexité, cette release est la plus volumineuse du projet (tableau 40). Elle solde le backlog du produit : à son terme, les soixante récits ont été livrés.

Sprint	Période	Objectif du sprint	Récits	Pts
Sprint 5	18 mai – 14 juin	Transformer l'outil d'analyse en plateforme gouvernée et traçable	US-30 à 35, 37 à 39, 43 à 51	77
Sprint 6	15 juin – 12 juil.	Couvrir le travail à plusieurs, la restitution documentaire et la reproductibilité	US-24, 25, 36, 41, 42, 52 à 60	83
Total de la release			32 récits	160

TABLE 40 Backlog de la release 3

L'incrément attendu en fin de release est la plateforme complète, conteneurisée et vérifiée automatiquement à chaque livraison.

5.2 Sprint 5 : Dossier patient et gouvernance

Le sprint précédent a livré un outil d'analyse. Ce cinquième sprint, qui ouvre la release, en fait un système d'information clinique : les examens sont rattachés à des patients, les fichiers volumineux archivés hors base, et la plateforme ouverte à plusieurs établissements sous le contrôle d'un administrateur.





5.2.1 Objectif du sprint

Trois exigences structuraient ce sprint.

La première était la persistance. Une analyse sans dossier n'a pas d'usage clinique : il fallait rattacher chaque examen à un patient, conserver l'historique et cloisonner les données de chaque praticien.

La deuxième était le traitement des fichiers volumineux. Un enregistrement pèse plusieurs centaines de mégaoctets. Le conserver en base aurait dégradé les sauvegardes et les temps de réponse sans bénéfice transactionnel.

La troisième était la gouvernance. Ouvrir la plateforme à plusieurs centres suppose de pouvoir créer des comptes, en révoquer l'accès sans détruire de données, et tracer les actions sensibles.

5.2.2 Sprint Backlog

Le sprint a embarqué dix-huit récits pour 77 points de complexité (tableau 41).

ID	Module	Récit utilisateur	Tâches	Estim.
US-31 à 35	Dossier patient	En tant que médecin, je veux constituer et suivre mon registre de patients	Modéliser patients et examens Créer le registre et l'historique Cloisonner les données par praticien	19 pts
US-37 à 39	Archivage cloud	En tant que système, je veux archiver les fichiers volumineux sans bloquer l'interface	Intégrer le client de stockage objet Transférer en arrière-plan avec suivi Délivrer des liens signés à durée limitée	18 pts
US-43 à 47	Comptes et licences	En tant qu'administrateur, je veux gérer le cycle de vie des comptes médecins	Créer et lister les comptes Suspendre, réactiver et fixer l'échéance Gérer les établissements de rattachement	21 pts
US-30, 48 à 51	Traçabilité	En tant qu'administrateur, je veux tracer et exporter les actions sensibles	Journaliser auteur, horodatage et adresse Appliquer statut et licence à la connexion Exporter le journal au format tabulaire	19 pts

TABLE 41 Sprint Backlog — Sprint 5





5.2.3 Analyse

5.2.3.1 Diagramme des cas d'utilisation




FIGURE 49 Diagramme des cas d'utilisation du sprint 5 — dossier patient et gouvernance





5.2.3.2 Description textuelle des cas d'utilisation

Titre	Gérer le cycle de vie d'un compte médecin
Acteur	Administrateur
Description	Créer un compte praticien, en suspendre ou réactiver l'accès, fixer son échéance de licence et le rattacher à un établissement
Préconditions	L'administrateur est authentifié
Scénario de base	1. L'administrateur ouvre le registre des médecins. 2. Il crée un compte en renseignant identité, adresse et échéance de licence. 3. Le système vérifie l'unicité de l'adresse et hache le mot de passe initial. 4. Le système journalise la création. 5. L'administrateur peut ensuite suspendre, réactiver ou prolonger le compte.
Scénario alternatif	• 3a — L'adresse est déjà enregistrée : la création est refusée. • 5a — Le praticien a perdu son accès : réinitialisation avec mot de passe temporaire.

TABLE 42 Description textuelle du cas « Gérer le cycle de vie d'un compte »

5.2.4 Conception

5.2.4.1 Diagramme d'états

Un examen traverse une succession d'états. Cette modélisation explicite un point important : un examen reste consultable même si l'archivage échoue, car les résultats d'analyse sont stockés en base indépendamment des fichiers.




FIGURE 50 États successifs d'un examen ; l'échec d'archivage ne bloque pas l'exploitation des résultats.





5.2.5 Réalisation

5.2.5.1 Persistance et cloisonnement

Le modèle de données repose sur huit tables, présentées au chapitre 2. Le rattachement direct du patient à son praticien référent fonde le cloisonnement : chaque route vérifie, après le rôle, que la ressource demandée appartient bien à l'appelant. Un médecin ne peut donc pas accéder au dossier d'un confrère, même en devinant un identifiant.

5.2.5.2 Archivage sur stockage objet

Les fichiers volumineux sont confiés à un service de stockage objet compatible avec l'interface S3. Chaque objet est rangé dans un préfixe portant le nom du patient et nommé selon le motif `patient_date_alea`, ce qui rend l'arborescence lisible depuis la console du fournisseur sans consulter la base.

Le point central de cette réalisation est le transfert en arrière-plan. Attendre la fin du téléversement avant d'afficher les résultats aurait immobilisé le praticien pendant plusieurs minutes. L'enchaînement retenu est donc : l'analyse est exécutée, les résultats sont affichés, l'examen est créé en base, puis le transfert démarre sans bloquer l'interface. Une vignette flottante affiche la progression et disparaît quelques secondes après son achèvement.

Un échec de transfert n'interrompt rien : il est signalé dans la vignette, et l'examen reste pleinement exploitable.

Les liens d'accès aux fichiers sont signés et expirent au bout de vingt-quatre heures. Une subtilité a été traitée : les enregistrements et les fichiers tabulaires sont servis avec une en-tête forçant le téléchargement, tandis que les images et les comptes rendus restent affichables dans le navigateur.

Ces références ne sont jamais transmises telles quelles : les schémas de sortie déclarent un validateur qui intercepte toute référence de fichier au moment de composer la réponse et la remplace par un lien signé. Aucune route ne peut donc divulguer une référence brute par inadvertance, puisque la conversion est appliquée par le schéma et non par la route.

5.2.5.3 Administration et cycle de vie des licences

Un compte peut être actif, suspendu ou en attente, et porte une date d'échéance. Ces trois conditions sont évaluées à chaque ouverture de session, avec un message distinct pour chacune, de sorte que le praticien sache s'il doit contacter son administrateur ou renouveler son abonnement.

Ce dispositif permet de révoquer un accès sans détruire de données, ce qui est la seule manière acceptable de gérer une fin de contrat sur un système qui héberge des dossiers médicaux.




FIGURE 51 *Registre des médecins et gestion des licences*





FIGURE 52 *Gestion des établissements rattachés*

5.2.5.4 Traçabilité

Chaque action sensible inscrit dans le journal son auteur, son rôle, son horodatage, la nature de l'action et l'adresse d'origine. Sont journalisées les connexions, les créations de compte, les modifications de statut et les réinitialisations de mot de passe. Le journal est exportable au format tabulaire pour un contrôle externe.

La table est délibérément dénormalisée : elle recopie l'adresse et le rôle plutôt que de référencer le compte, afin que la trace survive à la disparition de celui-ci.



FIGURE 53 *Journal d'audit : consultation et export*

5.2.5.5 Limites au regard du règlement européen

Le système n'est pas conforme au règlement général sur la protection des données. Trois écarts subsistent.

Les données patient ne sont pas chiffrées au repos : elles reposent sur le chiffrement offert par le service de stockage et par le système de fichiers de la base, sans couche applicative supplémentaire. Le droit à l'effacement n'est pas outillé : aucune procédure n'efface un patient et ses fichiers archivés en une opération. Enfin, aucune durée de conservation n'est définie ni appliquée.

Ces trois points relèvent d'un travail de mise en conformité qui dépasse le périmètre d'un projet de fin d'études, mais qu'une mise en service réelle imposerait.

5.2.6 Revue du sprint

Ce sprint a doté la plateforme d'une mémoire et d'une gouvernance. Les examens sont désormais rattachés à des patients, les fichiers volumineux archivés hors base et accessibles uniquement par des liens signés, et l'administrateur dispose des outils nécessaires pour ouvrir la plateforme à plusieurs établissements.

Un principe directeur guide ces choix : ne jamais faire attendre le praticien, et ne jamais laisser un incident technique compromettre l'exploitation d'un examen.

Le sprint suivant, dernier du projet, couvre le travail à plusieurs, la restitution documentaire et l'industrialisation du déploiement.





5.3 Sprint 6 : Collaboration, restitution et industrialisation

Ce dernier sprint couvre trois volets complémentaires : le travail à plusieurs, la production du document qui sort du système, et l'industrialisation du déploiement.

5.3.1 Objectif du sprint

L'interprétation d'un enregistrement difficile se fait rarement seul. Le premier objectif était donc de permettre à un praticien de solliciter un confrère, en gardant la discussion attachée à l'examen concerné.

Le deuxième objectif était la restitution. Un système d'aide au diagnostic dont on ne peut rien extraire n'a pas d'usage : il fallait produire un compte rendu composable, adapté au destinataire.

Le troisième était l'industrialisation : rendre le déploiement reproductible et vérifier automatiquement qu'une modification ne casse rien.

5.3.2 Sprint Backlog

Le sprint a embarqué quatorze récits pour 83 points de complexité (tableau 43).





ID	Module	Récit utilisateur	Tâches	Estim.
US-53 à 55	Collaboration	En tant que médecin, je veux solliciter un confrère sur un examen précis	Modéliser fils et messages rattachés à un examen Créer l'interface de discussion Centraliser les sollicitations reçues	18 pts
US-24, 25, 42	Annotation et normes	En tant que médecin, je veux annoter une époque et situer chaque métrique par rapport aux normes	Enregistrer les notes horodatées à l'époque Synchroniser l'hypnogramme annoté Comparer les métriques aux valeurs de référence	15 pts
US-36, 41	Restitution	En tant que médecin, je veux composer et exporter mon compte rendu	Sélectionner les sections à inclure Produire le document paginé Afficher le tableau de bord de la patientèle	13 pts
US-52, 56 à 60	Industrialisation	En tant que développeur, je veux un déploiement reproductible et vérifié automatiquement	Conteneuriser les trois services Orchestrer la pile en une commande Automatiser contrôles et construction d'images Traduire l'interface et ajouter le thème sombre Visualiser la chaîne de traitement des modèles	37 pts

TABLE 43 Sprint Backlog — Sprint 6





5.3.3 Analyse

5.3.3.1 Diagramme des cas d'utilisation




FIGURE 54 Diagramme des cas d'utilisation du sprint 6 — collaboration et restitution

5.3.3.2 Description textuelle des cas d'utilisation

Titre	Solliciter un confrère sur un examen
Acteurs	Médecin demandeur, confrère sollicité
Description	Ouvrir une discussion rattachée à un examen afin de recueillir un avis, en conservant le contexte clinique
Préconditions	Les deux praticiens sont authentifiés ; l'examen existe
Scénario de base	1. Le médecin ouvre la fiche du patient et sélectionne l'examen. 2. Il demande la liste des confrères disponibles. 3. Il sélectionne un confrère et rédige sa demande. 4. Le système crée le fil, ou réutilise celui qui existe déjà, et enregistre le message. 5. Le confrère consulte sa boîte de réception et répond dans le même fil.
Scénario alternatif	• 4a — Un fil existe déjà entre ces deux praticiens sur cet examen : le message y est ajouté plutôt que d'ouvrir un doublon.

TABLE 44 Description textuelle du cas « Solliciter un confrère »





5.3.4 Conception

5.3.4.1 Diagramme de séquence objet

La figure 55 détaille la sollicitation d'un confrère. Deux points la caractérisent. L'ouverture du fil est idempotente : l'interface applicative recherche d'abord une discussion existante entre les deux praticiens sur le même examen, et ne la crée qu'à défaut. L'envoi d'un message est ensuite une opération distincte, soumise à la vérification que l'appelant participe bien au fil.




FIGURE 55 Diagramme de séquence objet du sprint 6 — sollicitation d'un confrère

5.3.5 Réalisation

5.3.5.1 Consultations confraternelles

Un fil de discussion est rattaché à un examen et à exactement deux praticiens. L'intérêt de ce dispositif est que la discussion reste attachée à l'examen : le correspondant dispose du contexte sans qu'il faille le lui transmettre. Une





vue centralisée rassemble toutes les sollicitations reçues.



FIGURE 56 *Fil de discussion rattaché à un examen*

5.3.5.2 Annotation et comparaison aux normes

Le praticien peut annoter une époque précise de l'hypnogramme ; ses observations sont conservées et peuvent être synchronisées vers le dossier, ce qui archive l'hypnogramme annoté aux côtés des autres pièces.

Chaque métrique AASM est par ailleurs accompagnée de sa plage de référence et d'une comparaison aux valeurs de la cohorte. Une valeur hors norme est signalée visuellement, et une liste d'alertes cliniques reprend en clair les anomalies détectées.

5.3.5.3 Production du compte rendu

Le compte rendu est produit côté client : les sections retenues sont converties en images par capture du rendu, puis assemblées dans un document paginé. Cette approche garantit que le document reproduit exactement ce que le praticien a validé à l'écran, sans qu'un moteur de rendu distinct puisse introduire un écart.

Le praticien choisit les sections à inclure : hypnogramme, métriques AASM, classe de sévérité, facteurs explicatifs, tracés bruts et comparaison aux normes. Cette composition à la carte répond à des destinataires différents : un confrère n'attend pas le même document qu'un dossier d'assurance. Le document est ensuite archivé au même titre que les autres pièces.



FIGURE 57 *Compte rendu clinique généré*

5.3.5.4 Multilinguisme et thème sombre

L'interface est intégralement traduite en français et en anglais, les chaînes étant centralisées dans un catalogue unique et la bascule immédiate. Un thème sombre est également disponible, adapté à la lecture nocturne : un praticien qui interprète un enregistrement le fait rarement en plein jour.





FIGURE 58 *Tableau de bord du médecin en thème sombre*

5.3.5.5 Conteneurisation

La pile est décrite par un fichier d'orchestration unique qui déclare trois services.

Service	Image de base	Port	Particularité
Base de données	postgres:15-alpine	5432	Volume persistant, sonde de disponibilité
Interface applicative	python:3.10-slim	8000	PyTorch en version processeur installé en premier
Serveur web	node:20-alpine puis nginx:alpine	80	Construction en deux étapes, redirection du routage client

TABLE 45 Services de la pile conteneurisée

Le fichier de construction de l'interface applicative comporte une particularité : PyTorch y est installé depuis l'index dédié aux processeurs, *avant* les autres dépendances. Sans cette précaution, l'installation télécharge plusieurs gigaoctets de bibliothèques inutiles en déploiement (l'inférence en production s'exécutant sur processeur) et fait échouer la construction sur une machine de développement.

La sonde de disponibilité de la base est également indispensable : sans elle, l'interface applicative démarrerait avant que la base n'accepte les connexions et échouerait à créer son schéma.

5.3.5.6 Intégration continue

Une chaîne d'intégration continue s'exécute à chaque livraison sur la branche principale et à chaque proposition de fusion.





Travail	Étapes
Interface applicative	Installation des dépendances avec PyTorch en version processeur ; contrôle syntaxique de tous les modules ; démarrage d'une instance PostgreSQL de service ; démarrage réel de l'application ; vérification du schéma OpenAPI et de la présence des points d'entrée attendus ; contrôle du cloisonnement des rôles
Interface utilisateur	Installation reproductible des dépendances ; analyse statique ; construction de production ; publication du bundle en tant qu'artefact
Images de conteneur	Construction des deux images avec cache de couches, conditionnée à la réussite des deux travaux précédents

TABLE 46 Travaux de la chaîne d'intégration continue

Le travail portant sur l'interface applicative va au-delà du contrôle syntaxique : il démarre réellement l'application contre une base éphémère, puis exerce trois vérifications de comportement. Un appel sans jeton doit recevoir un refus d'authentification ; une connexion administrateur doit délivrer un jeton ; et ce jeton d'administrateur, présenté au registre des patients, doit recevoir un refus d'autorisation. Ces trois assertions couvrent l'essentiel du cloisonnement des rôles et échoueraient immédiatement si une dépendance de sécurité venait à disparaître au fil d'une modification.



FIGURE 59 Exécution de la chaîne d'intégration continue

5.3.6 Revue du sprint

Ce dernier sprint a complété la plateforme sur ses trois derniers volets. Les praticiens peuvent solliciter un confrère sans quitter le contexte de l'examen, composer un compte rendu adapté à son destinataire, et travailler dans la langue et le thème de leur choix.

La pile est entièrement conteneurisée et vérifiée par une chaîne d'intégration continue qui démarre réellement l'application et contrôle le cloisonnement des rôles.

5.4 Revue de la release 3

5.4.1 Incrément livré

La release a livré ses 160 points en deux sprints, portant le total livré à 358 points sur les six sprints du projet (tableau 47).





Élément attendu	Réalisation	État
Dossier patient	Registre des patients, historique des examens, cloisonnement des données par praticien	✓
Archivage	Stockage objet, transfert en arrière-plan, liens signés valables vingt-quatre heures	✓
Gouvernance	Cycle de vie des comptes et des licences, établissements, journal d'audit exportable	✓
Collaboration et restitution	Fils de discussion rattachés aux examens, annotation, compte rendu composable	✓
Industrialisation	Pile de trois conteneurs, intégration continue, interface bilingue et thème sombre	✓

TABLE 47 Revue de la release 3 : incrément attendu et incrément livré

5.4.2 Validation fonctionnelle

En complément de la chaîne d'intégration continue, une campagne de scénarios fonctionnels a été exécutée manuellement à chaque fin de sprint. Le tableau 48 en présente l'état sur la version livrée au terme de la release.





N°	Scénario	Critère de réussite	État
1	Connexion valide	Jetons délivrés, espace de travail ouvert	✓
2	Connexion refusée	Compte suspendu ou licence expirée rejeté avec message distinct	✓
3	Cloisonnement des rôles	Un médecin n'atteint aucune route d'administration	✓
4	Cloisonnement des patients	Un médecin n'accède pas au dossier d'un confrère	✓
5	Analyse complète	Enregistrement déposé, hypnogramme et métriques affichés	✓
6	Montage incomplet	Dérivation absente : repli appliqué, analyse aboutie	✓
7	Fichier invalide	Format non reconnu refusé avec message explicite	✓
8	Prédiction de sévérité	Classe, probabilités et facteurs restitués	✓
9	Import de rapport externe	Formulaire prérempli depuis un fichier tabulaire ou balisé	✓
10	Archivage en arrière-plan	Résultats affichés avant la fin du transfert	✓
11	Échec d'archivage	Transfert interrompu : examen consultable, erreur signalée	✓
12	Lien expiré	Lien réutilisé après échéance : accès refusé	✓
13	Annotation d'époque	Note enregistrée et retrouvée au rechargement	✓
14	Consultation confraternelle	Message émis par un praticien, reçu par l'autre	✓
15	Compte rendu	Document produit avec les seules sections sélectionnées	✓
16	Journal d'audit	Actions sensibles tracées et exportées	✓
17	Bascule linguistique	Aucune chaîne non traduite sur le parcours principal	✓
18	Démarrage de la pile	Trois services opérationnels en une commande	✓

TABLE 48 Scénarios de validation fonctionnelle

Cette approche a une limite : une campagne manuelle n'est ni reproductible ni exhaustive, et elle ne protège pas contre les régressions entre deux exécutions. Les trois assertions automatisées constituent un premier filet de sécurité, mais une véritable couverture de tests reste à construire.

5.4.3 Rétrospective

La rétrospective de la dernière release porte autant sur ce qu'elle a livré que sur ce qu'il resterait à faire avant une mise en service.

Ne jamais faire attendre le praticien. Le principe directeur de la release (afficher les résultats avant la fin de l'archivage, et ne jamais laisser un incident technique compromettre l'exploitation d'un examen) s'est révélé structurant, du transfert en arrière-plan jusqu'au cycle de vie de l'examen.





Assumer les écarts réglementaires. Le chiffrage applicatif des données au repos, le droit à l'effacement et les durées de conservation ne sont pas couverts. Ces écarts, documentés au sprint 5, dépassent le périmètre du projet mais conditionnent toute mise en service réelle.

Construire une couverture de tests. La campagne de validation reste manuelle, donc ni reproductible ni exhaustive. Les assertions de sécurité de la chaîne d'intégration continue en constituent l'amorce.

Conclusion

Cette dernière release a complété HYPNORIA sur l'ensemble de son périmètre fonctionnel. Les examens sont rattachés à des patients et archivés hors base, l'administrateur gouverne l'ouverture de la plateforme à plusieurs établissements, les praticiens peuvent solliciter un confrère et composer un compte rendu adapté à son destinataire, et la pile se déploie en une commande sous le contrôle d'une chaîne d'intégration continue.

Au terme des trois releases, les soixante récits du backlog (358 points de complexité) ont été livrés. La conclusion générale en dresse le bilan et ouvre sur les perspectives.





Conclusion générale et perspectives

Bilan du travail

Ce projet est parti d'un constat en trois volets. L'interprétation d'un enregistrement polysomnographique mobilise plusieurs heures d'expertise par patient, ce qui limite l'accès au diagnostic bien davantage que la capacité d'enregistrement. Cette interprétation n'est pas parfaitement reproductible, l'accord entre scoreurs plafonnant autour de 83 %. Et les modèles d'apprentissage profond qui pourraient absorber ce volume restent opaques, ce qui interdit au praticien d'engager sa responsabilité sur une prédiction dont il ignore les motifs.

HYPNORIA répond à ces trois exigences par une plateforme organisée en deux étages d'apprentissage. Le premier classe automatiquement les stades du sommeil à partir d'un enregistrement brut ; le second exploite l'hypnogramme produit pour estimer la sévérité d'un syndrome d'apnées obstructives, en exposant les facteurs qui déterminent chaque prédiction. Autour de ces modèles, la plateforme fournit la chaîne applicative attendue en contexte clinique : dossier patient, archivage sécurisé, annotation, compte rendu composable, collaboration entre praticiens et traçabilité des actions.

Mené selon le cadre Scrum en trois releases de deux sprints chacune, le projet a livré les soixante récits de son backlog. Les objectifs fixés au chapitre 1 ont été atteints dans les proportions que résume le tableau ci-dessous.

Bilan au regard des objectifs		
Objectif	Réalisation	État
Automatiser le scoring des stades	Douze modèles entraînés et quatre ensembles construits ; meilleure exactitude de 91,66 % pour un κ de 0,853	atteint
Prédire la sévérité du SAOS	Modèle à quatre classes sur 53 variables ; 57,0 % d'exactitude et plus de 95 % des prédictions à un cran près	atteint
Expliquer chaque prédiction	Attributions par valeurs de Shapley sur le modèle de sévérité, restituées en facteurs aggravants et protecteurs	partiellement
Fournir la chaîne applicative	Trente points d'entrée, deux rôles, archivage cloud, collaboration, journal d'audit, interface bilingue, pile conteneurisée	atteint

L'objectif d'explicabilité n'est que partiellement atteint : les explications produites portent sur la prédiction de sévérité, non sur la classification des stades. Les cartes de saillance et les poids d'attention initialement envisagés pour les modèles profonds n'ont pas été exposés dans l'interface. Le mécanisme d'attention existe pourtant dans l'architecture récurrente, et ses poids sont calculés à chaque inférence : les rendre visibles relève d'un travail de restitution, non de modélisation.





Apports du projet

Sur le plan scientifique, ce travail apporte une comparaison systématique de trois familles d'architectures sur quatre configurations de montage et de granularité, là où la littérature compare le plus souvent un modèle à des résultats publiés dans des conditions différentes. Il apporte surtout deux résultats nuancés que la pratique courante tend à masquer. D'une part, l'empilement dépasse le meilleur modèle isolé sur les quatre configurations de classification, mais ne dépasse le vote moyen que sur trois d'entre elles : la comparaison au vote moyen, rarement rapportée, révèle que l'apport du méta-apprentissage est réel mais modeste et conditionné au désaccord entre les modèles combinés. D'autre part, sur la prédiction de sévérité, l'empilement *dégrade* légèrement la meilleure ligne de base, ce que nous avons rattaché à un défaut de diversité entre trois modèles tous fondés sur des arbres.

Sur le plan technique, la contribution tient moins aux modèles qu'à l'intégration. Peu de travaux académiques livrent la chaîne complète permettant à un praticien d'exploiter un modèle : de la lecture d'un fichier hétérogène jusqu'au compte rendu archivé, en passant par la gestion des comptes, le cloisonnement des données et la traçabilité. Deux décisions d'ingénierie ont pesé : l'arbitrage de résidence des données en mémoire, qui a préservé la qualité de convergence au prix du volume, et l'archivage en arrière-plan, qui affiche les résultats avant la fin du transfert.

Sur le plan personnel, ce projet aura été l'occasion de mener un cycle complet, de la revue de littérature à la conteneurisation, et surtout d'apprendre à distinguer un résultat d'un artefact de protocole. La découverte, en rédigeant le chapitre 4, que les matrices de confusion produites par le pipeline de sévérité portaient des étiquettes permutées, a été plus formatrice que bien des succès : elle rappelle qu'un chiffre n'a de valeur que si l'on sait exactement ce qu'il mesure.

Limites

Quatre limites bornent la portée de ce travail. Elles ont été analysées en détail dans les chapitres correspondants ; nous les rassemblons ici.

La première est méthodologique. Les modèles de base ont été évalués sur un découpage au niveau des époques et non des sujets. Chaque patient contribuant environ un millier de fenêtres, le modèle a vu, pour presque chaque époque de test, d'autres époques du même patient et de la même nuit. Les métriques rapportées mesurent donc la classification d'une époque inconnue chez un patient connu, et surestiment vraisemblablement la performance en situation clinique. S'y ajoute le fait que les ensembles ont été évalués selon un protocole différent, ce qui rend les deux séries de chiffres non comparables entre elles.

La deuxième tient au corpus. Les 196 enregistrements retenus représentent 3,4 % de la cohorte disponible, et ils ont été sélectionnés par filtrage sur la complétude du montage plutôt que par tirage aléatoire. La diversité des morphologies et des conditions d'enregistrement y est moindre que dans la cohorte complète.

La troisième concerne l'explicabilité, incomplète comme indiqué plus haut, et dont la nature doit être précisée : les attributions expliquent le comportement du modèle, non le phénomène physiologique. Une contribution élevée signale une influence sur la prédiction, jamais un lien de causalité.

La quatrième est applicative. Les routes d'inférence ne sont pas protégées par le contrôle d'accès, la conformité au règlement européen reste incomplète sur le chiffrement au repos, le droit à l'effacement et les durées de conservation, et la validation repose sur une campagne manuelle plutôt que sur une couverture de tests automatisés.

Perspectives

Les travaux à mener se hiérarchisent selon qu'ils conditionnent la validité des résultats, la mise en service ou l'extension du système.





Consolider la validité des résultats

La ré-évaluation complète sur un découpage par sujets est la priorité. Il s'agit d'appliquer un protocole unique (tirage aléatoire des sujets, séparation stricte entre entraînement, validation et test) aux douze modèles de base comme aux quatre ensembles. Aucune modification d'architecture n'est nécessaire : seul le découpage change. Les chiffres obtenus seront probablement inférieurs à ceux rapportés ici, mais ils seront comparables entre eux et transposables à la pratique clinique.

La validation externe sur la cohorte MESA, dont l'accès a été obtenu mais qui n'a pas été exploitée, constituerait la seconde étape : elle mesurerait la capacité du système à généraliser à une population et à un protocole d'acquisition différents.

L'élargissement du corpus suit. Il suppose de renoncer à la résidence intégrale en mémoire, donc de concevoir un chargement par blocs qui n'affame pas le processeur graphique, par exemple en préchargeant le bloc suivant pendant le traitement du bloc courant.

Préparer la mise en service

L'authentification des routes d'inférence est une correction d'une ligne par route, à appliquer de part et d'autre. La mise en conformité réglementaire demande davantage : chiffrement applicatif des données au repos, procédure d'effacement d'un patient et de ses fichiers en une opération, définition et application de durées de conservation.

La couverture de tests automatisés doit être construite à trois niveaux : unitaire sur la chaîne de traitement du signal, d'intégration sur les points d'entrée, et de bout en bout sur le parcours d'analyse. Les trois assertions de sécurité déjà présentes dans la chaîne d'intégration continue en constituent l'amorce.

La validation clinique, enfin : aucun praticien n'a évalué le système en conditions réelles. Une étude de concordance entre le scoring automatique et celui d'un technicien expérimenté, sur un échantillon d'enregistrements, mesurerait ce que les métriques ne disent pas : la confiance qu'un professionnel accorde à l'outil.

Étendre le système

Deux extensions relèvent des promesses initiales du cahier des charges et restent pertinentes.

Le lissage contextuel des transitions exploiterait le fait qu'un hypnogramme n'est pas une suite d'époques indépendantes : certaines transitions sont physiologiquement improbables, et une fenêtre glissante sur les probabilités prédites corrigerait les aberrations isolées. L'implémentation est simple et le gain attendu porte précisément sur l'indice de fragmentation, qui alimente le modèle de sévérité.

L'explicabilité des modèles de classification compléterait celle déjà en place sur la sévérité. Les poids d'attention du modèle récurrent sont calculés à chaque inférence sans être exploités ; les exposer indiquerait au praticien quels instants de l'époque ont déterminé la décision. Des cartes de saillance sur le modèle convolutif apporteraient une information complémentaire. Les réserves formulées dans la littérature sur la valeur explicative de l'attention [44, 45] devront toutefois être rappelées dans l'interface.

Enfin, le passage à l'échelle suppose de séparer le moteur d'inférence de l'interface applicative, afin de dimensionner indépendamment les ressources de calcul et celles de service, et de remplacer les migrations au démarrage par un outil de migration versionnée.

Mot de la fin

Ce projet ne prétend pas remplacer l'expertise humaine. Un modèle qui atteint le niveau d'accord observé entre deux experts ne fait pas mieux qu'un expert : il fait la même chose, plus vite et de manière parfaitement reproductible. Dans un domaine où le temps d'expertise disponible constitue le facteur limitant, le gain est déjà réel.

La transparence compte cependant autant que la performance brute. Un système qui expose les facteurs de sa décision permet au praticien de la valider, de la contester, et de conserver la responsabilité du diagnostic. C'est la condition à laquelle un outil d'aide à la décision peut être employé au chevet du patient.





Bibliographie

- [1] R. B. BERRY, S. F. QUAN, A. R. ABREU et al. *The AASM Manual for the Scoring of Sleep and Associated Events : Rules, Terminology and Technical Specifications*. Version 2.6. American Academy of Sleep Medicine. Darien, Illinois, 2020.
- [2] A. RECHTSCHAFFEN et A. KALES. *A Manual of Standardized Terminology, Techniques and Scoring System for Sleep Stages of Human Subjects*. Washington, D.C. : U.S. Government Printing Office, 1968.
- [3] A. V. BENJAFIELD, N. T. AYAS, P. R. EASTWOOD et al. « Estimation of the global prevalence and burden of obstructive sleep apnoea : a literature-based analysis ». In : *The Lancet Respiratory Medicine* 7.8 (2019), p. 687-698.
- [4] J. M. MARIN et al. « Long-term cardiovascular outcomes in men with obstructive sleep apnoea-hypopnoea with or without treatment with continuous positive airway pressure : an observational study ». In : *The Lancet* 365.9464 (2005), p. 1046-1053.
- [5] T. YOUNG et al. « Estimation of the clinically diagnosed proportion of sleep apnea syndrome in middle-aged men and women ». In : *Sleep* 20.9 (1997), p. 705-706.
- [6] V. K. KAPUR, D. H. AUCKLEY, S. CHOWDHURI et al. « Clinical Practice Guideline for Diagnostic Testing for Adult Obstructive Sleep Apnea ». In : *Journal of Clinical Sleep Medicine* 13.3 (2017), p. 479-504.
- [7] R. S. ROSENBERG et S. VAN HOUT. « The American Academy of Sleep Medicine Inter-scoring Reliability Program : Sleep Stage Scoring ». In : *Journal of Clinical Sleep Medicine* 9.1 (2013), p. 81-87.
- [8] H. DANKER-HOPFE, P. ANDERER, J. ZEITLHOFFER et al. « Interrater reliability for sleep scoring according to the Rechtschaffen & Kales and the new AASM standard ». In : *Journal of Sleep Research* 18.1 (2009), p. 74-84.
- [9] A. SUPRATAK et al. « DeepSleepNet : A Model for Automatic Sleep Stage Scoring Based on Raw Single-Channel EEG ». In : *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 25.11 (2017), p. 1998-2008.
- [10] M. PERSLEV, S. DARKNER, L. KEMPFNER et al. « U-Sleep : resilient high-frequency sleep staging ». In : *npj Digital Medicine* 4.72 (2021).
- [11] B. GOODMAN et S. FLAXMAN. « European Union Regulations on Algorithmic Decision-Making and a "Right to Explanation" ». In : *AI Magazine* 38.3 (2017), p. 50-57.





- [12] A. SUPRATAK et Y. GUO. « TinySleepNet : An Efficient Deep Learning Model for Sleep Stage Scoring based on Raw Single-Channel EEG ». In : *42nd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC)*. 2020, p. 641-644.
- [13] H. PHAN, K. MIKKELSEN, O. Y. CHEN et al. « SleepTransformer : Automatic Sleep Staging with Interpretability and Uncertainty Quantification ». In : *IEEE Transactions on Biomedical Engineering* 69.8 (2022), p. 2456-2467.
- [14] H. PHAN, O. Y. CHEN, P. KOCH et al. « XSleepNet : Multi-View Sequential Model for Automatic Sleep Staging ». In : *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44.9 (2022), p. 5903-5915.
- [15] L. FRAIWAN, K. LWEESY, N. KHASAWNEH et al. « Automated sleep stage identification system based on time–frequency analysis of a single EEG channel and random forest classifier ». In : *Computer Methods and Programs in Biomedicine* 108.1 (2012), p. 10-19.
- [16] O. TSINALIS et al. « Automatic Sleep Stage Scoring with Single-Channel EEG Using Convolutional Neural Networks ». In : *arXiv preprint arXiv :1610.01683* (2016).
- [17] S. CHAMBON, M. N. GALTIER, P. J. ARNAL et al. « A Deep Learning Architecture for Temporal Sleep Stage Classification Using Multivariate and Multimodal Time Series ». In : *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 26.4 (2018), p. 758-769.
- [18] S. MOUSAVI, F. AFGHAH et U. R. ACHARYA. « SleepEEGNet : Automated sleep stage scoring with sequence to sequence deep learning approach ». In : *PLOS ONE* 14.5 (2019), e0216456.
- [19] E. ELDELE, Z. CHEN, C. LIU et al. « An Attention-Based Deep Learning Approach for Sleep Stage Classification With Single-Channel EEG ». In : *IEEE Transactions on Neural Systems and Rehabilitation Engineering* 29 (2021), p. 809-818.
- [20] K. SCHWABER et J. SUTHERLAND. *The Scrum Guide : The Definitive Guide to Scrum — The Rules of the Game*. scrumguides.org, 2020.
- [21] A. GRAMFORT, M. LUESSI, E. LARSON et al. « MEG and EEG data analysis with MNE-Python ». In : *Frontiers in Neuroscience* 7.267 (2013).
- [22] A. PASZKE, S. GROSS, F. MASSA et al. « PyTorch : An Imperative Style, High-Performance Deep Learning Library ». In : *Advances in Neural Information Processing Systems 32 (NeurIPS)*. 2019, p. 8024-8035.
- [23] F. PEDREGOSA, G. VAROQUAUX, A. GRAMFORT et al. « Scikit-learn : Machine Learning in Python ». In : *Journal of Machine Learning Research* 12 (2011), p. 2825-2830.
- [24] T. CHEN et C. GUESTRIN. « XGBoost : A Scalable Tree Boosting System ». In : *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, p. 785-794.





- [25] G. KE, Q. MENG, T. FINLEY et al. « LightGBM : A Highly Efficient Gradient Boosting Decision Tree ». In : *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017, p. 3146-3154.
- [26] S. M. LUNDBERG et S.-I. LEE. « A Unified Approach to Interpreting Model Predictions ». In : *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017, p. 4765-4774.
- [27] S. M. LUNDBERG, G. ERION, H. CHEN et al. « From local explanations to global understanding with explainable AI for trees ». In : *Nature Machine Intelligence* 2.1 (2020), p. 56-67.
- [28] G.-Q. ZHANG, L. CUI, R. MUELLER et al. « The National Sleep Research Resource : towards a sleep data commons ». In : *Journal of the American Medical Informatics Association* 25.10 (2018), p. 1351-1358.
- [29] B. KEMP, A. H. ZWINDERMAN, B. TUK et al. « Analysis of a sleep-dependent neuronal feedback loop : the slow-wave microcontinuity of the EEG ». In : *IEEE Transactions on Biomedical Engineering* 47.9 (2000), p. 1185-1194.
- [30] A. L. GOLDBERGER, L. A. N. AMARAL, L. GLASS et al. « PhysioBank, PhysioToolkit, and PhysioNet : Components of a New Research Resource for Complex Physiologic Signals ». In : *Circulation* 101.23 (2000), e215-e220.
- [31] S. F. QUAN, B. V. HOWARD, C. IBER et al. « The Sleep Heart Health Study : design, rationale, and methods ». In : *Sleep* 20.12 (1997), p. 1077-1085.
- [32] S. HOCHREITER et J. SCHMIDHUBER. « Long Short-Term Memory ». In : *Neural Computation* 9.8 (1997), p. 1735-1780.
- [33] D. BAHDANAU, K. CHO et Y. BENGIO. « Neural Machine Translation by Jointly Learning to Align and Translate ». In : *3rd International Conference on Learning Representations (ICLR)*. 2015.
- [34] A. VASWANI, N. SHAZEER, N. PARMAR et al. « Attention Is All You Need ». In : *Advances in Neural Information Processing Systems 30 (NeurIPS)*. 2017, p. 5998-6008.
- [35] J. COHEN. « A Coefficient of Agreement for Nominal Scales ». In : *Educational and Psychological Measurement* 20.1 (1960), p. 37-46.
- [36] D. H. WOLPERT. « Stacked generalization ». In : *Neural Networks* 5.2 (1992), p. 241-259.
- [37] K. M. TING et I. H. WITTEN. « Issues in Stacked Generalization ». In : *Journal of Artificial Intelligence Research* 10 (1999), p. 271-289.
- [38] L. BREIMAN. « Random Forests ». In : *Machine Learning* 45.1 (2001), p. 5-32.
- [39] K. SIMONYAN, A. VEDALDI et A. ZISSERMAN. « Deep Inside Convolutional Networks : Visualising Image Classification Models and Saliency Maps ». In : *Workshop at the 2nd International Conference on Learning Representations (ICLR)*. 2014.





- [40] R. R. SELVARAJU, M. COGSWELL, A. DAS et al. « Grad-CAM : Visual Explanations from Deep Networks via Gradient-based Localization ». In : *IEEE International Conference on Computer Vision (ICCV)*. 2017, p. 618-626.
- [41] M. SUNDARARAJAN, A. TALY et Q. YAN. « Axiomatic Attribution for Deep Networks ». In : *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, p. 3319-3328.
- [42] M. T. RIBEIRO, S. SINGH et C. GUESTRIN. « "Why Should I Trust You ?" : Explaining the Predictions of Any Classifier ». In : *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, p. 1135-1144.
- [43] L. S. SHAPLEY. « A Value for n-Person Games ». In : *Contributions to the Theory of Games, Volume II*. Sous la dir. de H. W. KUHN et A. W. TUCKER. Princeton University Press, 1953, p. 307-317.
- [44] S. JAIN et B. C. WALLACE. « Attention is not Explanation ». In : *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*. 2019, p. 3543-3556.
- [45] S. WIEGREFFE et Y. PINTER. « Attention is not not Explanation ». In : *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2019, p. 11-20.

